


神经网络泛化误差的高维动力学

High-dimensional dynamics of
generalization error in neural networks

Madhu S. Advani · Andrew M. Saxe
Haim Sompolinsky



完整中文译注版

非官方译本 · 正文、原图、附录与参考文献

Neural Networks 132 (2020), 428–446

[doi:10.1016/j.neunet.2020.08.022](https://doi.org/10.1016/j.neunet.2020.08.022)

中文译注整理：2026 年 9 月 7 日

版本、署名与使用说明

原作 Madhu S. Advani, Andrew M. Saxe, Haim Sompolsky. *High-dimensional dynamics of generalization error in neural networks*. *Neural Networks*, 132 (2020), 428–446.

作者单位 a. 美国哈佛大学脑科学中心, Cambridge, MA 02138; b. 以色列耶路撒冷希伯来大学 Edmond and Lily Safra 脑科学中心, Jerusalem 91904. Advani 与 Saxe 对本研究贡献相同 (原注 1)。Saxe 为通讯作者, 原文邮箱为 andrew.saxe@psy.ox.ac.uk; 其当时现地址为英国牛津大学实验心理学系, Oxford OX2 6GG (原注 2)。

稿件记录 2020 年 1 月 4 日收到; 2020 年 8 月 18 日收到修订稿; 2020 年 8 月 24 日接受; 2020 年 9 月 5 日在线发表。

版权与许可 © 2020 The Authors. Published by Elsevier Ltd. 原稿首页明确声明本文按 Creative Commons Attribution 4.0 International (CC BY 4.0) 许可开放获取。许可链接: <https://creativecommons.org/licenses/by/4.0/>。原作版权归作者; 本译本保留原作者署名与出处, 中文翻译、译注及新增版式亦按 CC BY 4.0 提供。转载或改编时应署名、附许可链接并说明改动, 不得暗示原作者或出版方认可本译本。

非官方中文译注 本文由 Codex 辅助完成中文翻译、原生 L^AT_EX 重排和校勘, 供学术阅读与对照使用, 未经原作者或出版社审订。新增内容包括本说明、阅读导言、符号表、封面示意和以“译注”标示的注释。正文、公式和原图依据工作区内 19 页正式出版 PDF 整理; 英文原稿未改动。

编辑原则 保留原章节层级、公式 (1) 至 (79)、图 1 至图 14, 以及作者一年份式参考文献结构。原稿无独立表格、编号定理或另行编排的补充附件; 附录 A–C 全部收入。图内英文标签保留, 图题完整译为中文; 公式与正文均可编辑、可检索。原文存在少量公式记号或适用条件问题, 本版保留原式并作显式说明, 未将其默认为新结论。参考文献保留原英文著录, 以便检索。

原稿核验: 19 页; 期刊页码 428–446; 文字可提取; 未加密。

原文 DOI: <https://doi.org/10.1016/j.neunet.2020.08.022>

阅读导言

这篇论文研究的是学习的时间过程：同一个网络为何先学到有用规律，随后又把噪声拟合进去；参数数目超过样本数后，为何网络仍可能泛化良好。其出发点是能精确求解的线性学生—教师模型，再逐步过渡到深层线性网络、固定随机特征的非线性网络，以及两层均训练的网络与 MNIST 实验。

全文的关键对象是样本输入相关矩阵的特征值。对浅层线性模型，每个特征方向独立演化，学习时间约为 τ/λ 。小而非零的特征值既学习缓慢，又会放大噪声；恰为零的特征值则形成冻结子空间，永久保留初始化分量。两者作用不同，是理解本文的第一道关口。

第二道关口是区分两种误差恶化。本文把训练时间过长造成的测试误差回升称为“过度训练”（overtraining）；谈论模型规模时，“过拟合”（overfitting）也指复杂度提高后的泛化损失。后文式（38）又把有限样本导致的一项误差专门命名为“过拟合误差”。阅读时应结合时间轴、规模轴和误差分解三种语境，而不把“没有观察到过拟合”理解为网络完全没有拟合噪声。

建议阅读路径

第 2.1 节与图 2：从谱分布读懂冻结方向与慢模态。

第 2.2–2.5 节：早停、岭回归与初始化如何共同控制误差。

第 3–5 节：哪些直觉延续到深层与非线性网络。

第 6–7 节：双降、记忆和 Rademacher 复杂度如何联系。

附录 A–C：核对动力学约化、权重范数与误差分解。

论文中的线性结果具有明确的分布、归一化和极限假设；非线性结论则结合了理论近似与数值证据。特别是“大模型更好”的表述应与小初始化、早停、信噪比及所考察模型类一起阅读。本版在与推导直接相关的位置提示原稿的记号疑点；这些说明属于译注，并非原作者论断。

符号与术语

符号	含义及约定
$P, N, \alpha = P/N$	样本数、浅层输入维数 / 参数数目、测量密度；高维极限中二者同阶增长。
N_i, N_h, N_t, N_o	输入、学生隐藏层、教师隐藏层与输出的维数 / 单元数。
$D, W_1, \dots, W_D$	深层线性网络的权重矩阵数和各层权重；连同输入共有 $D+1$ 层。
$X, y; \bar{w}, w(t)$	训练输入矩阵、教师标签；教师权重与随时间变化的学生权重。权重常按行向量记。
$\epsilon, \sigma_\epsilon^2$	输出噪声及其方差； $\epsilon(x)$ 在误差分解中还可指模型逼近残差。
$\sigma_w^2, (\sigma_w^0)^2$	教师权重方差、学生初始化权重方差。
SNR, INR	信噪比 $\sigma_w^2/\sigma_\epsilon^2$ ；初始化噪声比 $(\sigma_w^0)^2/\sigma_w^2$ 。
τ, t^{opt}	与学习率成反比的时间常数；最优早停时刻。
$E_t, E_g, E_g^*, E_g^{\text{late}}$	训练误差、泛化误差、最优早停泛化误差、长时间训练后的泛化误差。
E_∞, E_{est}	最佳可达的逼近误差；相对于该下界的估计误差。
Σ^{xx}, Σ^{yx}	输入相关矩阵 XX^T 与输入—输出相关矩阵 yX^T ；此处未除以样本数。
V, Λ, λ_i	输入相关矩阵的特征向量矩阵、特征值对角阵与第 i 个特征值。
$\rho^{\text{MP}}, \lambda_\pm$	Marchenko–Pastur 谱分布；其连续支撑的左右端点。
$\tilde{s}, \bar{z}, z$	对齐向量；特征基中的教师与学生权重。
$\gamma, \hat{w}_{L_2}$	岭正则化强度及相应估计量。
$\phi(x), \Phi$	固定特征 / 隐藏层表示；训练样本的隐藏活动矩阵。
$C, R; \hat{C}, \hat{R}$	总体特征相关和输出—特征相关；经验对应量（未必采用相同归一化）。
$w^*, w_\parallel^*$	总体最优权重；原文用于表示数据子空间内的受限最优权重。见附录 C 译注。
$P_\parallel, P_\perp$	到样本特征张成空间与其正交补的投影。
$A^\dagger, \text{Tr}$	Moore–Penrose 伪逆；矩阵的迹。

术语统一：generalization 为“泛化”；early stopping 为“早停”；frozen subspace 为“冻结子空间”；approximation error 为“逼近误差”；overcomplete 为“过完备”；overparameterized 为“过参数化”；ReLU 为“修正线性单元”；double descent 为“双降”。原文图中 MP 即 Marchenko–Pastur，Train/Test 为训练 / 测试，Oracle 为预言机下界。

目录

版本、署名与使用说明	i
阅读导言	ii
符号与术语	iii
摘要	v
1 引言	1
2 浅层线性神经网络中的泛化动力学	2
2.1 高维极限下的精确解	3
2.2 早停的有效性	5
2.3 L_2 正则化	7
2.4 权重范数随信噪比的增长	7
2.5 初始权重大小对泛化性能的影响	9
2.6 训练误差动力学	10
3 深层线性神经网络中的泛化动力学	11
4 首层权重冻结的神经网络：泛化动力学与最优规模	13
5 两层均训练的网络	18
5.1 真实数据集：MNIST	18
6 双下降、插值、记忆与泛化	20
7 Rademacher 复杂度与非线性神经网络中的过拟合抑制	21
8 讨论	24
利益冲突声明	25
致谢	25
附录 A 深层线性神经网络的动力学	26
附录 B 最优权重范数随信噪比的增长	27
附录 C 泛化误差的分解	27
参考文献	30

摘要

我们分析了使用梯度下降训练的大型神经网络的平均泛化动力学。研究聚焦于具有实际意义的“高维”情形：网络中的自由参数数目与数据集中的样本数同阶，甚至更多。利用随机矩阵理论和线性模型的精确解，我们推导了学习过程中泛化误差与训练误差的动力学，并分析其如何依赖数据维数与学习问题的信噪比。我们发现，梯度下降学习的动力学天然有助于保护大型网络，使其避免过度训练和过拟合。过度训练在中等网络规模处最严重：此时有效自由参数数目等于样本数；因此，缩小或扩大网络均可减轻过度训练。此外，在高维情形下，较低的泛化误差要求从较小的初始权重开始。

随后，我们转向非线性神经网络，表明把网络做得非常大不会损害泛化性能；相反，即使不采用早停或任何形式的正则化，也能减轻过度训练。我们识别了过完备模型中支撑这一行为的两种新现象：其一，存在一个在梯度下降下不发生学习的权重冻结子空间；其二，高维情形的统计性质产生条件更好的输入相关结构，从而抑制过度训练。我们表明，通常应用 Rademacher 复杂度等理论，不能准确预测深度神经网络的泛化表现；为此，我们推导了另一种界，它纳入冻结子空间和条件改善效应，并与模拟中观察到的行为定性吻合。

关键词 神经网络；泛化误差；随机矩阵理论

1 引言

深度学习方法已在许多任务上取得优异性能 (LeCun, Bengio, & Hinton, 2015; Schmidhuber, 2015), 但其学习行为仍不透明。引人注目的是, 即便规模非常大的网络, 也能凭借相对有限的样本获得良好的泛化性能 (Canziani, Paszke, & Culurciello, 2017; He, Zhang, Ren, & Sun, 2016; Simonyan & Zisserman, 2015)。例如, VGG 深度目标识别网络含有 1.55 亿个参数, 却能在仅含 120 万个样本的 ImageNet 上训练后良好泛化 (Simonyan & Zisserman, 2015)。这一观察提出了重要问题: 哪些理论原则能够解释数据有限时的这种良好表现? 给定数据集大小, 模型应有多复杂, 才能使泛化误差最优?

本文研究若干简单训练情景中, 平均泛化误差在“高维”情形下的动力学: 样本数 P 与参数数目 N 都很大 ($P, N \rightarrow \infty$), 但二者之比 $\alpha = P/N$ 有限 (例如 Advani, Lahiri, & Ganguli, 2013)。我们从能够得到解析结果的简单模型出发, 逐步增加复杂性, 以验证这些发现是否在更现实的设置中近似成立。我们主要考虑学生—教师情景: 一个“教师”神经网络生成可能带噪声的样本, 供一个“学生”网络学习 (Saad & Solla, 1995; Seung, Sompolinsky, & Tishby, 1992; Watkin, Rau, & Biehl, 1993)。这一简单设置保留了复杂问题中的许多权衡: 在什么条件下, 学生会过拟合教师网络生成的特定样本? 学生网络的复杂度 (例如隐藏单元数) 与教师网络的复杂度应当具有什么关系?

首先, 第 2 节研究线性神经网络。对于浅层网络, 将随机矩阵理论结果与学习动力学结合, 可以写出批量梯度下降动力学关于数据量和信噪比的精确解。这与大量关于浅层网络的既有工作相关 (Bai & Silverstein, 2010; Baldi & Chauvin, 1991; Baldi & Hornik, 1995; Benaych-Georges & Rao, 2011, 2012; Chauvin, 1990; Dodier, 1995; Dunmur & Wallace, 1999; Hoyle & Rattray, 2007; Kinouchi & Caticha, 1995; Krogh & Hertz, 1992; LeCun, Kanter, & Solla, 1991; Seung et al., 1992)。结果表明, 将早停与小范数权重初始化相结合, 能够有效抵御过度训练; 当样本数等于模型参数数目时, 过度训练最为严重。

对于深层线性神经网络, 我们在第 3 节把完全耦合、非线性的梯度下降动力学约化为少得多的参数, 这些参数仅通过一个全局标量耦合。该约化适用于任意深度的网络, 并揭示深度如何通过动力学影响训练时间。这里的推导与此前关于深层线性网络动力学的解析研究 (Saxe, McClelland, & Ganguli, 2014) 不同: 我们不假定输入相关矩阵与输入—输出相关矩阵可同时对角化。结果表明, 在这一简单的深层线性情形中, 泛化误差与浅层线性情形具有定性相似的行为。

接着, 第 4 节转向非线性网络。我们考虑从非线性教师网络生成的数据集中学习非线性学生网络。模拟表明, 从线性分析中获得的定性直觉能够很好地推广到非线性设置。值得注意的是, 灾难性的过度训练出现在模型复杂度与训练集大小恰好匹配时, 而缩小或扩大模型都可缓解这一问题。此外, 我们没有发现过拟合的证据: 随着学生变大, 最优早停时的泛化误差不断减小, 即便学生网络远大于教师网络, 隐藏神经元数也远多于训练样本数。这与早期神经网络数值研究 (Caruana, Lawrence, & Giles, 2001), 以及近年来超大规模神经网络的良好泛化表现一致 (例如 Belkin, Hsu, Ma, & Mandal, 2019; Simonyan & Zisserman, 2015; Spigler et al., 2018)。在这一设置下, 我们发现网络越大越好, 唯一代价是较大模型带来的计算开销。

我们还分析一个两层网络, 以获得理解这些数值结果的理论直觉。具有宽隐藏层的学生网络能够有很强的表达能力 (Barron, 1993), 即使第一层随机选取并在训练期间固定不变, 也不例外。然而, 在这一设置中, 当隐藏单元数 N_h 大于样本数 P 时, 我们的线性解意味着: 隐藏层协方差矩阵的 $N_h - P$ 个零特征值方向不会发生学习。因此, 继续增大网络, 实际上不会增加网络能够学得函数的复杂度。而且, 当 N_h 超过 P 后继续增大时, 非零特征值会被推离原点, 从而降低学生权重能够学得的最大范数; 这似乎隐式降低了较晚停止训练时的模型复杂度和过拟合。最后, 通

过 MNIST 数据集上的模拟，我们表明，真实数据集也会再现这些定性现象。

复杂模型的优异表现，似乎与直接应用 VC 维和 Rademacher 泛化界所得的结论矛盾 (Zhang, Bengio, Hardt, Recht, & Vinyals, 2017)。第 6、7 节讨论这些问题。结果表明，早停与小范数权重初始化的组合策略对模型的有效复杂度起到正则化作用。这一双重策略限制网络中的权重范数，从而限制 Rademacher 复杂度。这类似于支持向量机采用的策略：即使核具有无限 VC 维，只要训练过程在训练数据上找到大间隔（低范数权重向量）解，仍可保持泛化能力。因此，尽管大型深度神经网络确实可以拟合随机标签，以小范数权重初始化并由梯度训练的深度神经网络，会优先学习较简单的函数；只要存在一致的规律可学，便能良好泛化。

值得注意的是，即使没有早停，更大的网络仍可能泛化得更好 (Belkin, Hsu, Ma et al., 2019)。为理解这一点，我们对第一层权重固定的两层非线性神经网络，推导了一个纳入梯度下降动力学的 Rademacher 复杂度替代界。我们表明：不发生学习的冻结子空间限制了复杂度；过完备模型中，隐藏层数据的特征值谱具有更大的间隙，从而抑制过度训练。该界为大型网络的泛化行为提供了新的直觉，并与我们的模拟及既有研究定性一致：即便没有早停，只要 $N_h > P$ ，增加隐藏单元数 N_h 也会减轻过度训练。

我们的结果开始阐明深度网络中多样的学习行为，并支持一种逐渐形成的看法：优先选择较大的模型，再在之后进行剪枝。

2 浅层线性神经网络中的泛化动力学

首先，我们研究一个简单情形：接收 N 维输入的浅层线性神经网络的泛化动力学。我们采用标准的学生—教师形式，这一设置已由统计力学方法广泛研究（综述见 Engel & Van Den Broeck, 2001；Seung et al., 1992；Watkin et al., 1993；与本节线性分析更接近的设置见 Baldi & Chauvin, 1991；Baldi, Chauvin, & Hornik, 1990；Baldi & Hornik, 1995；Chauvin, 1990；Dunmur & Wallace, 1999；Kinouchi & Caticha, 1995；Krogh & Hertz, 1992；LeCun et al., 1991）。权重向量为 $w(t) \in \mathbb{R}^{1 \times N}$ 的学生网络，使用权重为 $\bar{w} \in \mathbb{R}^{1 \times N}$ 的教师网络生成的样本进行训练（见图 1）。教师在 P 个输入 $X \in \mathbb{R}^{N \times P}$ 与相应的标量输出 $y \in \mathbb{R}^{1 \times P}$ 之间实现一个带噪声的线性映射：

$$y = \bar{w}X + \epsilon. \quad (1)$$

其中 $\epsilon \in \mathbb{R}^{1 \times P}$ 表示教师输出中的噪声。我们将噪声 ϵ 和教师权重 $\bar{w}$ 分别建模为从零均值、方差为 σ_ϵ^2 和 $\sigma_{\bar{w}}^2$ 的随机分布独立同分布抽取。信噪比 $\text{SNR} \equiv \sigma_{\bar{w}}^2 / \sigma_\epsilon^2$ 刻画数据集底层规律相对于教师输出噪声的强度。在求解中，我们对 $\bar{w}$ 的所有可能实现取平均，计算泛化动力学，以得到不依赖具体学习问题的一般特征。最后，假定输入元素 X_j^μ 独立同分布地取自均值为零、方差为 $1/N$ 的高斯分布，使每个样本的期望平方范数为一： $\langle \|x^\mu\|_2^2 \rangle = 1$ 。

学生网络用数据集 $\{y, X\}$ 训练，以准确预测新输入 $x \in \mathbb{R}^N$ 对应的输出。学生为浅层线性网络，因此其预测 $\hat{y} \in \mathbb{R}$ 就是 $\hat{y}^\mu = w(t) \cdot x^\mu$ 。为学习参数 w ，学生网络通过梯度下降尝试最小化 P 个训练样本上的均方误差。训练误差为

$$E_t(t) = \frac{1}{P} \sum_{\mu=1}^P \|y^\mu - \hat{y}^\mu\|_2^2, \quad (2)$$

对该误差函数进行全批量连续时间梯度下降（它很好地近似了大步长的离散时间批量梯度下降），




图 1 从带噪声的线性教师学习。(A) 向权重向量为 $\bar{w}$ 的教师网络提供随机输入 x ，再用方差为 σ_ϵ^2 的噪声污染教师输出，生成包含 P 个样本的数据集 $\mathcal{D} = \{x^\mu, y^\mu\}$ ， $\mu = 1, \dots, P$ 。(B) 学生网络随后在该数据集 $\mathcal{D}$ 上训练。(C) 学生网络在全批量梯度下降训练中的动力学示例。训练误差（蓝色）单调下降。测试误差又称泛化误差（黄色），这里可由式 (4) 精确计算；它在最优早停时刻 t^* 降至最小值 E_g^* ，随后在更长时间上上升至 E_g^{late} ，这种现象称为过度训练。由于教师输出含噪声，即使拥有无限训练数据，最好的学生网络（“oracle”，绿色）也只能达到有限的泛化误差。这一误差即逼近误差 E_∞ 。测试误差与这一最佳可能误差之差为估计误差 E_{est} 。（原文提示：颜色解释见文章网络版；本译本保留原图颜色。）

得到动力学方程

$$\tau \dot{w}(t) = yX^T - wXX^T. \quad (3)$$

这里 τ 是与学习率成反比的时间常数。我们的主要目标是理解网络泛化性能如何随训练演化，也就是研究训练过程中，对一个未见过的样本取平均所得的泛化误差：

$$E_g(t) = \langle (y - \hat{y})^2 \rangle_{x,y}. \quad (4)$$

其中 $\langle \cdot \rangle_{x,y}$ 对可能的输入 x 和标签 y 取平均。泛化误差具有自平均性：当数据维数足够高，即 $N, P \rightarrow \infty$ 时，数据与模型的所有随机实现应具有相同的性能。

2.1 高维极限下的精确解

泛化性能如何随训练演化？其长期行为是明确的：如果权重从零初始化并训练足够长时间，权重向量 w 会收敛到使训练误差 (2) 最小的子空间，求解最小二乘回归问题：

$$w(t \rightarrow \infty) = yX^T(XX^T)^\dagger, \quad (5)$$

其中 $\dagger$ 表示 Moore–Penrose 伪逆。伪逆达到的误差，以及适用于非线性学生和教师的更一般动力学结果，早已为人所知 (Krogh & Hertz, 1992; LeCun et al., 1991; Seung et al., 1992)。这里我们明确研究参数被学得的时间过程，并探索其与现代深度学习现象的联系。

首先，对输入数据做奇异值分解 $X = V\Lambda^{1/2}U^T$ （其中 $U \in \mathbb{R}^{P \times N}$ ， $\Lambda^{1/2} \in \mathbb{R}^{N \times N}$ ， $V \in \mathbb{R}^{N \times N}$ ）。于是输入相关矩阵为

$$\Sigma^{xx} = XX^T = V\Lambda V^T. \quad (6)$$

再将输入—输出相关矩阵写成

$$\Sigma^{yx} = yX^T = \tilde{s}V^T, \quad (7)$$

其中行向量 $\tilde{s}$ 称为对齐向量，因为它与输入—输出相关性和输入相关性之间的对齐有关。

回到动力学式 (3)，作变量变换 $w = zV^T$ ，转而追踪向量 $z \in \mathbb{R}^{1 \times N}$ 。利用式 (7) 得

$$\tau \dot{z}(t) = \tilde{s} - z\Lambda. \quad (8)$$

为解释该方程，我们利用下式计算 $\tilde{s}$ ：

$$yX^T = \bar{w}XX^T + \epsilon X^T = \bar{z}\Lambda V^T + \tilde{\epsilon}\Lambda^{1/2}V^T, \quad (9)$$

这里定义 $\bar{z} = \bar{w}V$ ；在高斯白噪声假设下， $\tilde{\epsilon} \in \mathbb{R}^N$ 的各元素独立同分布地取自方差为 σ_ϵ^2 的高斯分布。 Σ^{yx} 的形式意味着 $\tilde{s} = \bar{z}\Lambda + \tilde{\epsilon}\Lambda^{1/2}$ ，因此式 (8) 可改写为

$$\tau \dot{z}_i = (\bar{z}_i - z_i)\lambda_i + \tilde{\epsilon}_i\sqrt{\lambda_i}, \quad i = 1, \dots, N. \quad (10)$$

各模态的学习速度相互独立，仅取决于该模态的特征值。后面将看到，深度学习情形下模态之间会发生耦合；浅层神经网络则没有这种耦合，因此可以直接求出各模态的动力学。 z 每个分量中的误差为

$$\bar{z}_i - z_i = (\bar{z}_i - z_i(0))e^{-\lambda_i t/\tau} - \frac{\tilde{\epsilon}_i}{\sqrt{\lambda_i}}(1 - e^{-\lambda_i t/\tau}). \quad (11)$$

由 z 的定义，泛化误差作为训练时间的函数为

$$E_g(t) = \frac{1}{N} \sum_i \langle (\bar{z}_i - z_i)^2 \rangle + \sigma_\epsilon^2 \quad (12)$$

$$= \frac{1}{N} \sum_i \left[(\sigma_w^2 + (\sigma_w^0)^2)e^{-2\lambda_i t/\tau} + \frac{\sigma_\epsilon^2}{\lambda_i}(1 - e^{-\lambda_i t/\tau})^2 \right] + \sigma_\epsilon^2. \quad (13)$$

第二个等号来自如下假设：教师权重 $\bar{w}$ 与学生初始权重 $w(0)$ 分别独立同分布地取自标准差为 $\sigma_{\bar{w}}$ 和 σ_w^0 的高斯分布。将数据协方差特征值的谱密度记为 $\rho(\lambda)$ ，泛化误差动力学可写为

$$\frac{E_g(t)}{\sigma_w^2} = \int \rho(\lambda) \left[(1 + \text{INR})e^{-2\lambda t/\tau} + \frac{(1 - e^{-\lambda t/\tau})^2}{\lambda \text{SNR}} \right] d\lambda + \frac{1}{\text{SNR}}, \quad (14)$$

这里除以 σ_w^2 以确定尺度，并定义初始化噪声比 $\text{INR} \equiv (\sigma_w^0)^2/\sigma_w^2$ 。

该泛化误差表达式包含两个随时间变化的项。第一项指数衰减至零，刻画权重初值与最终待学权重之间的距离。第二项从零开始，以指数方式趋近渐近值 $\sigma_\epsilon^2/\lambda_i$ ，对应于对这一批特定样本所含噪声的过拟合。这里有两点重要。第一，恰为零的特征值 ($\lambda_i = 0$) 对应没有学习动力学的方向 (式 (10) 右端恰为零)，因此参数 z_i 永远停留在 $z_i(0)$ 。这些方向构成一个不发生学习的冻结子空间。在原坐标基下，权重通常都会随学习改变；但旋转到输入数据的主成分方向，就会显现这些完全冻结的方向。因此，如果存在零特征值，权重初始化对泛化性能的影响即使经过任意长训练仍会持续。

第二，由于泛化误差第二项含有因子 $\sigma_\epsilon^2/\lambda_i$ ，较小的特征值造成最严重的过拟合。这是因为，投影到这些小特征值模态的噪声会造成网络权重大幅增长 (见式 (11))。因此，零与最小非零特征值之间较大的谱隙，能够自然地抵御过拟合。此外，较小特征值模态学习得最慢，这提示早停可能有效，下文将详细说明。最后，该表达式也揭示训练动力学收敛所需的时间。样本协方差中非零但很小的特征值会造成非常缓慢的动力学，因此梯度下降最小化训练误差所需时间的量级为 $t = \tau/\lambda_{\min}$ 。

泛化动力学 (13) 揭示了样本输入协方差矩阵特征值谱的关键作用。若有大量小特征值，学生权重范数的增长会导致泛化性能较差。

许多有意义的情形中，高维极限下样本协方差的特征值谱分布已知：输入维数 N 与样本数 P 同时趋于无穷，而测量密度 $\alpha = P/N$ 保持有限。特别地，当输入独立同分布地取自零均值、方差 $1/N$ 的高斯分布时， XX^T 的特征值分布在高维极限下趋近 Marchenko–Pastur 分布 (LeCun et al., 1991; Marchenko & Pastur, 1967):

$$\rho^{\text{MP}}(\lambda) = \frac{1}{2\pi} \frac{\sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}}{\lambda} + \mathbf{1}_{\alpha < 1}(1 - \alpha)\delta(\lambda), \quad (15)$$

其支撑集为 $\lambda = 0$ 或 $\lambda \in [\lambda_-, \lambda_+]$ ，其余位置为零。分布边缘为 $\lambda_{\pm} = (\sqrt{\alpha} \pm 1)^2$ ，因而依赖样本数相对于输入维数的比例。图 2A 给出三种测量密度的特征值密度。在欠采样情形 $\alpha < 1$ ，样本数少于输入维数，大量特征值恰为零，形成原点处的狄拉克 δ 项。这对应数据相对于模型规模稀缺的情形。在临界采样情形 $\alpha = 1$ ，参数数目恰好等于样本数。此时分布在原点附近发散，出现极小特征值的概率增大，导致灾难性的过度训练。最后，在过采样情形 $\alpha > 1$ ，样本数多于输入维数，对应数据充足的传统渐近情形；此时特征值分布远离原点。

图 2B 展示将式 (15) 代入式 (14) 所得的欠采样、临界采样和过采样情形的泛化动力学。三者均出现过拟合，但中间点 $\alpha = 1$ 处明显更严重。图 2C 系统展示若干训练时间下，泛化性能随 α 的变化，清楚显示 $\alpha = 1$ 处的发散。因此，测量密度接近 1 时，过度训练可能使泛化性能完全失效。图 3 比较理论与模拟，也验证了泛化误差预测式 (14)。

即使是如此简单的线性学生与教师设置，也产生了依赖数据集参数的复杂过度训练现象。下文将进一步探讨这些解的各个方面，并表明早停能有效抵御过度训练。

译注 式 (15) 的连续密度项只在 $[\lambda_-, \lambda_+]$ 上取值；在 $\lambda = 0$ 的原子质量应与连续部分分别理解。式 (11)、(13)、(14) 中出现 $1/\lambda$ 的项，在零特征值方向按 $\lambda \rightarrow 0$ 的极限解释：噪声学习项为零，而初始化误差保留。文中将 XX^T 称为协方差或相关矩阵，未再除以 P ；这一归一化决定了式 (15) 的谱边缘。

2.2 早停的有效性

图 2B 中的泛化曲线先改善一段时间，随后开始恶化，最终收敛到 $\lim_{t \rightarrow \infty} w(t)$ 所对应的性能。因此，存在一个最优停止时刻，在此提前终止训练，比长时间训练具有更好的泛化表现。直观地说，限制时间相当于对所学参数施加有效正则化。早停在实践中被广泛采用，也已有理论研究 (Amari, Murata, & Müller, 1996; Amari, Murata, Müller, Finke, & Yang, 1995; Baldi & Hornik, 1995; Biehl, Caticha, & Riegler, 2009; Chauvin, 1990; Dodier, 1995; Yao, Rosasco, & Caponnetto, 2007)。为数值求出最优停止时刻，可对式 (14) 关于 t 求导，并令结果为零，求解 t^{opt} 。为获得定性认识，我们先求使每个模态误差最小的停止时间，得到

$$t^{\text{opt}} = \frac{\tau}{\lambda} \log(\text{SNR} \lambda + 1), \quad (16)$$

这里为简便假设 $w(0) = 0$ 。图 4A 验证了这一标度关系。最优停止时间随信噪比按对数增长，其直觉是：质量较高的数据需要的正则化较弱。然而，当输入协方差存在一系列不同特征值时，一个共同的最优停止时刻不能使每个模态都达到最优。更一般地，必须选择使式 (14) 最小的 t ，才




图 2 Marchenko–Pastur 分布与高维学习动力学。(A) 训练样本数 P 与网络参数数目 N 的不同比值 ($\alpha = P/N$)，在输入相关矩阵中产生不同的特征值密度。 N 很大时，密度由 MP 分布 (15) 描述：它包含位于 $[\lambda_-, \lambda_+]$ 的“主体”，以及在 $\alpha < 1$ 时出现的零点 δ 峰。样本少于参数时 ($\alpha < 1$ ，左列)，一部分特征值恰为零（原点处箭头），其余明显大于零；样本数与参数数目相当时 ($\alpha = 1$ ，中列)，分布在原点附近发散，出现大量非零却任意小的特征值；样本多于参数时 ($\alpha > 1$ ，右列)，最小特征值也明显大于零。(B) 学习动力学。由式 (13)，小特征值最损害泛化误差，且学习最慢。因此，在 $\alpha = 1/2$ 和 $\alpha = 2$ 时，零附近的谱隙显著抑制过度训练 ($\alpha = 1/2$ 时恰为零的模式从不被学习，只贡献有限误差而不产生过度训练)。 $\alpha = 1$ 时存在任意小的特征值，过度训练显著。(C) 若干训练时间下泛化误差随 α 的变化，显示 $\alpha = 1$ 附近的明显尖峰。其他参数： $N = 100$ ， $\text{INR} = 0$ ， $\text{SNR} = 5$ 。颜色由红至黑，对应训练时间 $t/\tau = [5, 20, 50, 100, 1000]$ 。(颜色解释见原文网络版；本译本保留原色。)




图 3 泛化误差与训练误差动力学的理论和模拟比较。不同测量密度 ($\alpha = 1/2, 1, 2$) 下，泛化误差与训练误差动力学的理论预测均与模拟吻合。泛化误差（蓝色）和训练误差（绿色）的模拟带宽为 ± 2 个标准差，由 20 次试验产生；使用 $N = 300$ 、 $P = \alpha N$ ，输入、噪声和参数均为高斯分布， $\sigma_{\tilde{w}} = 1$ 、 $\sigma_w^0 = 0$ 、 $\text{SNR} = 5$ 。模拟与式 (14)、(26) 给出的理论预测高度一致。(颜色解释见原文网络版；本译本保留原色。)

能准确得到最优停止时间，图 4B 即采用这一数值方法。结果揭示了对测量密度的依赖：在测试误差达到峰值的 $\alpha = 1$ 附近，所需训练时间最长。

2.3 L_2 正则化

另一种方法是 L_2 正则化（也称权重衰减），因为临界情形下泛化误差的发散来自网络权重发散。这里将梯度下降早停的性能与 L_2 正则化比较；后者对应求解优化问题

$$\hat{w}_{L_2} = \arg \min_w \frac{1}{2} \left[\|y - wX\|_2^2 + \frac{\gamma}{2} \|w\|_2^2 \right]. \quad (17)$$

这种正则化给出的泛化误差（Advani & Ganguli, 2016b）为

$$\frac{E_g^{L_2}(\gamma)}{\sigma_w^2} = \int \rho(\lambda) \left[\frac{\gamma^2}{(\lambda + \gamma)^2} + \frac{\lambda}{\text{SNR}(\lambda + \gamma)^2} \right] d\lambda + \frac{1}{\text{SNR}}. \quad (18)$$

对上式关于 γ 求导，可知当正则化强度取信噪比的倒数 $\gamma = 1/\text{SNR} = \sigma_\epsilon^2/\sigma_w^2$ 时，算法性能最优。实际上，在噪声、参数和输入均独立同分布为高斯的假设下，没有算法能在泛化误差上优于最优 L_2 正则化（Advani & Ganguli, 2016a, 2016c）。这里我们要问：早停与这一最佳可能性能有多接近？如果将各模态的式 (16) 分别代入时变泛化误差表达式（即假设能够分别对每个模态早停），就得到与最优 L_2 正则化相同的泛化性能，这暗示两种方法有密切联系。不过，如上所述，实际的早停通常是次优的。图 5A 比较两种算法：它们的泛化性能非常接近，在该例中相对误差小于 3%，且在 $\alpha = 1$ 附近最大。网络权重初始化较大时，这种近乎最优的早停表现便会消失，如图 5B 所示。因此，当初始权重较小时，早停能够十分有效地抵御过度训练。

译注 原文式 (17) 外层已有 $1/2$ ，括号内又写 $\gamma/2$ ；按此字面表达，岭解分母为 $\lambda + \gamma/2$ ，与式 (18) 及附录 B 使用的 $\lambda + \gamma$ 约定不一致。此处保留原式；复核后续推导时，应采用 $\frac{1}{2}\|y - wX\|_2^2 + \frac{\gamma}{2}\|w\|_2^2$ 的通常约定。这里的 t^{opt} 是理论上借助真实泛化误差定义的最佳时刻，实际训练通常需验证集选择。

2.4 权重范数随信噪比的增长

较长的训练时间提供更多权重更新机会，因此，人们可能也会预期：最优早停时刻的权重范数会随信噪比系统变化。这里证明这一判断正确。假设学生的初始权重为零，最优二次正则化权重的平均范数（在附录 B 推导）随信噪比按下式增长：

$$\langle \hat{w}_{L_2}^2 \rangle = \sigma_w^2 \int \rho^{\text{MP}}(\lambda) \frac{\lambda}{\lambda + 1/\text{SNR}} d\lambda. \quad (19)$$

直观上，信噪比较低的数据需要较强正则化，从而使学得权重的范数更小。所学权重范数在两个极限之间变化： $\text{SNR} \rightarrow \infty$ 时 $\langle \hat{w}^2 \rangle \rightarrow \sigma_w^2$ ，而 $\text{SNR} \rightarrow 0$ 时 $\langle \hat{w}^2 \rangle \rightarrow 0$ 。

因此，数据的信噪比对最优正则化下所学权重范数起决定性作用。在这一设置中，恰当选择




图 4 数据质量与维数对最优停止时间的影响。(A) 低测量密度 $\alpha = 0.05$ 下信噪比对最优停止时间的影响，并与式 (16) 在 $\lambda = 1$ 时的预测比较；因为低测量密度时，MP 分布的非零特征值高度集中在 1 附近。(B) 低噪声 (SNR = 100) 极限下测量密度的影响。在 $\alpha = 1$ 附近需要更长训练，因为数据质量高，连小特征值方向上的权重也值得学习。两图绿色曲线均为利用式 (14) 对 t 作梯度下降所得的最优停止时间数值预测。(颜色解释见原文网络版；本译本保留原色。)




图 5 最优停止时的性能。(A) 早停的泛化误差 (红色星号) 与最优二次正则化回归 (蓝线) 比较。本例中两者相对误差不超过 3%；在非零特征值谱较宽的 $\alpha = 1$ 附近达到峰值。(B) 不同初始权重范数下，泛化误差随 α 的变化。在数据有限的情形，小初始权重对良好泛化至关重要。两图均固定 SNR = 5、 $\sigma_w^2 = 1$ ，因此即使测量密度 α 很大，泛化误差也因噪声而趋近非零值 $0.2 = 1/\text{SNR}$ 。

的算法会在数据更易预测时得到更大的网络权重。³

译注 式 (19) 使用的是按输入维数归一化的平均平方权重范数。其后关于高信噪比极限的原文叙述隐含了没有冻结方向的情形；当 $\alpha < 1$ 时，MP 分布在零点有质量 $1 - \alpha$ ，由式 (19) 直接得到的极限为 $\alpha\sigma_w^2$ 。这里保留原文叙述，并注明适用范围。

2.5 初始权重大小对泛化性能的影响

前几节已说明，在学生权重从零初始化 ($\text{INR} \approx 0$) 时，早停有效。早停使权重更接近初值，因此只有当初始权重较小时才提供有效正则化。为阐明初始化对泛化误差的影响，我们再次利用 $\text{INR} \approx 0$ 时早停与 L_2 正则化性能相近这一事实。如果学生初始权重不是零，而具有方差 $(\sigma_w^0)^2$ ，则最优 L_2 正则化强度为 $\gamma^{\text{opt}} = \sigma_\epsilon^2 / [(\sigma_w^0)^2 + \sigma_w^2]$ ，由此得到泛化误差

$$E_g = \frac{(\sigma_w^0)^2 + \sigma_w^2}{2} \left[1 - \alpha - \gamma^{\text{opt}} + \sqrt{(\gamma^{\text{opt}} + \alpha - 1)^2 + 4\gamma^{\text{opt}}} \right] + \sigma_\epsilon^2. \quad (20)$$

在高信噪比极限下，欠采样、等量采样和过采样三种情形中，泛化性能对初始权重的依赖具有三种不同的定性行为： $\alpha < 1$ 时为线性依赖， $\alpha = 1$ 时为平方根依赖， $\alpha > 1$ 时则没有依赖：

$$E_g \approx \begin{cases} [(\sigma_w^0)^2 + \sigma_w^2](1 - \alpha) + \sigma_\epsilon^2, & \alpha < 1, \\ \sqrt{(\sigma_w^0)^2 + \sigma_w^2} \sigma_\epsilon + \sigma_\epsilon^2, & \alpha = 1, \\ \sigma_\epsilon^2 \frac{\alpha}{\alpha - 1}, & \alpha > 1. \end{cases}$$

因而数据越多，权重初始化的影响越小。动力学解揭示了原因：当样本数相对于输入维数较少时，权重空间的许多方向没有样本落入，因而不会变化；初始化在这些方向上的分量将永久保留。因此，如图 5B 所示，在过参数化情形下，要使泛化性能最好，小权重初始化至关重要。即使样本数与模型规模相当 ($\alpha \approx 1$)，大范数初始化仍会损害最优早停策略，因为训练必须在初始权重影响完全衰减之前终止。因此，依据这一简单线性分析，通过早停与小范数权重初始化的双重策略，大型模型也能获得优异泛化。该策略几乎达到所研究设置下最佳可能的贝叶斯最优学习策略（最优 L_2 正则化）的性能，并在样本数可少于模型规模的高维情形中仍然有效。

译注 上面的分段近似强调主导标度，精确数值应使用式 (20)。本段“线性 / 平方根依赖”是相对于初始权重方差 $(\sigma_w^0)^2$ 而言。非零初始化与岭回归的对应应理解为对相对初值的权重改变量施加二次惩罚；若仅对最终权重施加通常的零中心岭惩罚并求得唯一最优解，所得解本身不依赖初始化。

³权重范数对信噪比的这种依赖，可能解释近期经验论文中的一些疑惑。例如，Zhang et al. (2017) 第 5 节比较在输入的非线性变换上学得的线性映射，发现范数较大的映射有时泛化得更好，表面上与依靠范数控制容量的泛化界矛盾。然而，根据我们的结果，如果一种非线性变换比另一种揭示更多信号，就应预期这种发现：产生较高信噪比的变换需要更长训练，得到更大权重范数，并取得更好的泛化性能。输入与输出之间更强的规律为较大范数提供了依据。但若比较在同一种非线性变换上学得的不同范数的线性映射，则会发现一个最优权重范数（可由早停近似找到）。

2.6 训练误差动力学

接下来考察学习中的训练误差动力学。我们将表明，它强烈依赖数据协方差的小特征值，而对信噪比的依赖较弱。从以下形式出发：

$$E_t(t) = \frac{1}{P} \|y - w(t)X\|_2^2. \quad (21)$$

代入数据的奇异值分解 $X = V\Lambda^{1/2}U^T$ 与 $w(t) = z(t)V^T$ ，得到

$$\frac{1}{P} \|y - z(t)\Lambda^{1/2}U^T\|_2^2. \quad (22)$$

在过采样设置 ($P > N$) 中，定义 $\tilde{U} = (U, U^\perp) \in \mathbb{R}^{P \times P}$ ；若 $P \leq N$ ，则令 $\tilde{U} = U$ ，使两种情形均有 $\tilde{U}\tilde{U}^T = I$ 。整理训练误差得

$$\begin{aligned} E_t(t) &= \frac{1}{P} \|y\tilde{U} - z(t)\Lambda^{1/2}U^T\tilde{U}\|_2^2 \\ &= \frac{1}{P} \|\tilde{\epsilon} + (\bar{z} - z(t))\Lambda^{1/2}\|_2^2 + \|\epsilon U^\perp\|_2^2. \end{aligned} \quad (23)$$

这里 $\tilde{\epsilon} = \epsilon U$ 。由式 (11)，线性网络的学习动力学满足

$$\tilde{\epsilon}_i + \sqrt{\lambda_i}(\bar{z}_i - z_i(t)) = [\sqrt{\lambda_i}(\bar{z}_i - z_i(0)) + \tilde{\epsilon}_i] e^{-\lambda_i t / \tau}. \quad (24)$$

因此训练误差可写为时间的函数：

$$E_t(t) = \frac{1}{P} \left[\sum_{i=1}^N (\sqrt{\lambda_i}(\bar{z}_i - z_i(0)) + \tilde{\epsilon}_i)^2 e^{-2\lambda_i t / \tau} + \sum_{j=1}^{P-N} (\tilde{\epsilon}_j^\perp)^2 \right], \quad (25)$$

其中 $\tilde{\epsilon}^\perp = \epsilon U^\perp$ ；当 $P \leq N$ 时，第二个求和为零。注意训练误差随时间严格下降。若 $P < N$ ，每个数据点被记忆后，训练误差趋近零。对噪声、参数和数据分布取平均，得到

$$\begin{aligned} \langle E_t(t) \rangle &= \frac{1}{\alpha} \int \rho(\lambda) [\lambda(\sigma_w^2 + (\sigma_w^0)^2) + \sigma_\epsilon^2] e^{-2\lambda t / \tau} d\lambda \\ &\quad + \left(1 - \frac{1}{\alpha}\right) \sigma_\epsilon^2 \mathbf{1}_{[\alpha > 1]}. \end{aligned} \quad (26)$$

图 3 表明上述理论预测与模拟结果相符。

这一训练误差动力学公式可能有助于解释近期的经验发现（例如 Arpit et al., 2017；Zhang et al., 2017）：神经网络并不难记忆带噪声的标签，为此只需稍长的训练时间。若考察 E_t 达到预先给定的小值之前所需的时间，向输出标签添加噪声只会使它略有增长。在可以记忆噪声的欠采样设置 ($\alpha < 1$) 中，足够晚时 ($t \gg \tau/\lambda_{\min}$)，训练误差按指数衰减，因此可很好地近似为

$$E_t(t) \propto \left(\lambda_{\min} + \frac{1}{\text{SNR}} \right) e^{-2\lambda_{\min} t / \tau}. \quad (27)$$

于是，要使训练误差达到与 δ 成比例的水平，所需时间的标度为

$$t \approx \frac{\tau}{2\lambda_{\min}} \log \left(\frac{\lambda_{\min} + 1/\text{SNR}}{\delta} \right). \quad (28)$$

因此，增加输出噪声方差，只应使记忆数据集所需的时间按对数增长。

译注 原文式 (23) 第二行最后一项缺少 $1/P$ ，由式 (21) 及后续式 (25) 可核对。式 (26) 在 $\alpha < 1$ 时，积分中的噪声项仅应遍历非零奇异模态；若直接将含零点原子质量的完整 MP 分布 (15) 代入该噪声项，会错误地产生残留训练误差。原文声称训练误差趋零及图 3 应按非零谱解释。原文同时使用了补零与约化奇异值分解的记号；零模态上 $\tilde{\epsilon}_i$ 不具有独立噪声驱动。这些约定不改变冻结子空间的主结论。

3 深层线性神经网络中的泛化动力学

前面几节的结果集中于最简单的浅层神经网络。现在我们转而考察：在一类简单的深度网络中，是否也会出现相似的定性性质。我们考虑一个深层线性学生网络（图 6A），其权重为 $W_1, \dots, W_D$ ，构成一个有 $D + 1$ 层的线性网络。给定输入 $x \in \mathbb{R}^N$ ，学生按照规则 $\hat{y} = W_D W_{D-1} \cdots W_2 W_1 x = W^{\text{tot}} x$ 产生标量预测 $\hat{y} \in \mathbb{R}$ 。除最后一层输出单个标量之外，我们起初不对各层的大小作任何假设。对训练均方误差进行连续时间梯度下降，得到动力学方程

$$\tau \frac{d}{dt} W_l = \left(\prod_{i=l+1}^D W_i \right)^T \left[\Sigma^{yx} - \left(\prod_{i=1}^D W_i \right) \Sigma^{xx} \right] \left(\prod_{i=1}^{l-1} W_i \right)^T. \quad (29)$$

这些方程既包含网络不同层权重之间的耦合，也包含权重之间的非线性相互作用。尽管深层线性网络计算的是简单的输入—输出映射，它们仍保留了非线性网络的若干重要特征：最显著的是，学习问题是非凸的 (Baldi 与 Hornik, 1989; Kawaguchi, 2016)，因而产生非线性的动力学轨迹 (Arora, Cohen 与 Hazan, 2018; Du, Hu 与 Lee, 2018; Fukumizu, 1998; Ji 与 Telgarsky, 2019; Saxe 等, 2014)。

我们希望找到一种简化表达式，能够很好地描述从小随机权重出发的动力学。直观地说，完整的梯度动力学包含使隐藏单元相互正交的排斥力，从而避免两个隐藏单元表示同一种输入特征。然而，以小随机权重初始化时，隐藏单元通常已经近似正交，因此，可以像 Saxe 等 (2014) 那样放心地忽略这些促使正交化的排斥力。首先，我们利用基于奇异值分解 (SVD) 的变量变换，减弱这些方程中的耦合。随后，在隐藏单元初始时完全解耦的假设下研究动力学；模拟验证了，当




图 6 深层线性网络动力学的约化。(A) 学生网络是深度为 $D + 1$ 的深层线性网络。(B–D) 在不同深度和参数设定下，比较小权重初始化网络的完整泛化动力学模拟（金色）与约化动力学模拟（绿色）。蓝色表示训练误差。关于本图图例中颜色的解释，读者可参阅本文的网络版。

初始随机权重很小时，这一假设仍能很好地近似完整动力学。

具体而言，已有研究观察到，以小权重初始化的深层线性网络，其梯度下降动力学会提取低秩结构 (Saxe 等, 2014)。据此，我们作如下变量变换： $W_1(t) = r_2 z(t) V^T$ ，其中 $z(t) \in \mathbb{R}^{1 \times N_i}$ 是一个行向量，编码与输入各主轴的重叠随时间的变化（回忆 $\Sigma^{xx} = V \Lambda V^T$ ）；并令 $W_l(t) = d(t) r_{l+1} r_l^T$ ， $l = 2, \dots, D$ ，其中向量 $r_i \in \mathbb{R}^{N_i \times 1}$ 是任意的单位范数向量（ $r_i^T r_i = 1$ ），表征网络内部表示的自由度；定义 $r_{D+1} = 1$ ，而 $d(t)$ 是编码表示随时间变化的标量。根据这些定义，

$$\begin{aligned} W^{\text{tot}} &= \left(\prod_{l=2}^D d(t) r_{l+1} r_l^T \right) r_2 z(t) V^T \\ &= d(t)^{D-1} z(t) V^T = u(t) z(t) V^T, \end{aligned}$$

其中我们定义标量 $u(t) = d(t)^{D-1}$ 。附录 A 证明，从这一形式出发的解会一直保持这一形式，并给出如下精确的动力学约化：

$$\tau \dot{u} = (D-1) u^{\frac{2D-4}{D-1}} \left(\tilde{s} z^T - u z \Lambda z^T \right), \quad (30)$$

$$\tau \dot{z} = u (\tilde{s} - u z \Lambda). \quad (31)$$

这些方程大幅简化了动力学。注意，如果每一层都有 $N_h = N_i$ 个隐藏单元，那么深度为 $D+1$ 的网络中的完整梯度下降涉及 $O(N_i^2 D)$ 个参数，而上述约化无论网络深度如何都只需要 $N_i + 1$ 个参数。图 6 比较了约化动力学所预测的泛化动力学，与不同深度、从小随机权重出发的网络在完整梯度下降下的模拟结果，证实在小随机权重初始化时，该约化能够准确刻画完整动力学。一系列研究表明，在远超本文学生—教师设定的广泛情形下，完整梯度下降动力学事实上会收敛到这些初始化条件所蕴含的低秩结构 (Arora 等, 2018; Du 等, 2018; Ji 与 Telgarsky, 2019)。我们的结果表明，一旦受到吸引而进入这个低秩解，泛化动力学就会呈现出一种特别简单的形式，揭示其与浅层情形的联系。

在约化动力学中，所有模式都通过全局标量 $u(t)$ 耦合在一起。比较式 (31) 和式 (8) 可见，这个标量乘在浅层动力学之前，因此在训练初期，当 z 与 u 都很小时，会产生一种特征性的减速（见图 6C–D 中的初始平台）。这一行为是深度动力学在所有权重均为零的鞍点附近初始化时的标志性特征；训练误差动力学中也发现了这种行为 (Goodfellow、Vinyals 与 Saxe, 2015; Saxe 等, 2014)。值得注意的是，在约化中，深度的全部影响都被压缩到标量 u 中，由它设定所有模式共同的全局动力学速率。除此之外，每个模式的动力学都与浅层情形类似，主要受相应特征值 λ_i 的大小驱动，较小特征值对应的模式学得较晚。这意味着，最优停止在深度网络中仍应有效，且结果与浅层情形相近。与浅层情形一样，特征值为零的模式不会发生进展，从而形成一个不发生任何学习的冻结子空间。因此，在数据有限的情形下，较大的初始权重范数同样会损害深层线性网络的泛化表现。

因此，对于产生标量输出的深层线性网络，我们的约化预测：它们的早停误差以及对权重初始化的敏感性，在定性上都与相应浅层网络相似。不过，深度在训练速度与泛化性能之间引入了潜在矛盾：小初始权重会显著减慢深度网络的学习，而大初始权重又可能损害高维情形下的泛化。这或许是完整非线性网络中某些观察结果的原因：某些初始化方法收敛很快，但泛化性能较差（例如 Mishkin 与 Matas, 2016）。




图 7 向非线性教师学习。(A) 教师网络 (N_t 个 ReLU)。(B) 学生网络 (N_h 个 ReLU, 但只训练输出权重)。(C) 模型复杂度的影响。在 $\text{SNR} = 1$ 、 $\text{INR} = 0$ 、 $N_i = 15$ 、 $N_t = 30$ 、训练样本数 $P = 300$ 的情形下, 最优早停误差随隐藏单元数 N_h 的变化。阴影表示 50 个随机种子的均值上下 1 个标准误。(D) 过度训练在接近训练样本数的中等复杂度处达到峰值, 即学生网络中的自由参数数目等于样本数 (300) 时。(E) 随机非线性神经网络隐藏层的特征值谱, 样本数为 $P = 1000$, 输入空间维数为 $N_i = 100$ 。我们考察三种情形; 如果只关注较小的特征值, 忽略远离原点、含 N_i 个特征值的次级簇, 就会得到与重新缩放的 Marchenko–Pastur 分布相似的特征值密度。左: 隐藏节点少于样本 ($N_h = 500$ 个隐藏单元), 原点附近存在间隙, 且没有零特征值。中: 隐藏节点数与样本数相等 ($N_h = 1000$), 原点附近没有间隙, 因此越接近原点, 特征值越可能出现。右: 隐藏节点多于样本 ($N_h = 2000$), 在原点出现概率质量为 0.5 的狄拉克 δ 峰, 并与下一个特征值之间存在间隙。(F) 若干模型的平均训练动力学, 展示中等复杂度下的过度训练。关于本图图例中颜色的解释, 读者可参阅本文的网络版。

4 首层权重冻结的神经网络: 泛化动力学与最优规模

在实际应用中, 非线性激活至关重要, 因为它们使网络能够表示复杂函数。本节通过引入一个固定的随机第一层, 并在隐藏层中使用非线性激活, 探讨研究线性网络所得到的定性认识在多大程度上能够迁移到非线性情形。非线性带来了模型复杂度这一关键问题: 给定问题的复杂度和可用训练样本的数量, 学生网络是否存在一个最优规模?

我们首先在学生—教师场景下模拟动力学 (Engel 与 Van Den Broeck, 2001; Saad 与 Solla, 1995; Seung 等, 1992; Watkin 等, 1993; Wei 与 Amari, 2008; Wei, Zhang, Cousseau, Ozeki 与 Amari, 2008), 如图 7A–B 所示。此时的教师是一个采用修正线性单元 (ReLU) 激活函数、具有 N_t 个隐藏神经元的单隐藏层神经网络。我们随机抽取该网络的参数。为计及 ReLU 非线性对方差的压缩, 我们将输入层到隐藏层权重的方差乘以 $\sqrt{2}$ (He 等, 2016; Saxe 等, 2014)。与前面一样, 我们抽取 P 个随机高斯输入, 获得教师输出 y , 再加入噪声, 生成一个数据集。学生网络本身也是一个单隐藏层 ReLU 网络, 具有 N_h 个隐藏单元, 随后在该数据集上训练, 以最小化均方误差。具体过程是: 只训练学生网络的第二层权重, 而第一层权重则保持为从与教师相同的分布中随机抽取的值。这个设定最接近浅层线性情形, 因为学习过程中只有学生网络从隐藏层到输出层的权重发生变化。由于非线性使解析结果难以获得, 我们转而通过模拟研究动力学。在图 7 的模拟中, 我们将教师参数固定为 $\text{SNR} = 1$ 、 $N_t = 30$ 和 $N_i = 15$, 训练样本数固定为 $P = 300$, 然后在—组隐藏层规模 $N_h = [1, \dots, 16326]$ 上训练学生模型, 其规模从样本数的 $1/300$ 到样本数的 54 倍不等。每个规模下的结果均对 50 个随机种子取平均。图 7C–D 展示了平均误差随学生神经元数量的变化。此外, 在没有教师网络的设定中, 虽然只能通过交叉验证估计泛化误差, 但当我们改用 MNIST 数据集时, 仍发现了教师—学生框架下观察到的定性趋势 (图 8)。




图 8 直接在数据上训练：使用 1024 个训练样本，在 MNIST 数字 7 与 9 的二分类任务上训练的两层 ReLU 网络。学生网络的第一层权重随机且固定。峰值较不明显，可能是因为计算资源限制了训练时间和最大模型规模（见正文）。

我们的目标是理解：线性分析所得的过度训练定性模式，是否也适用于这一非线性情形。我们得到以下经验观察。

过度训练发生在中等模型复杂度下。当数据集的样本数接近隐藏单元数 / 自由参数数目时，过度训练出现峰值，大模型的过度训练程度低于中等规模模型（图 7C-D）。因此，网络在定性上表现得类似于线性情形：当可训练参数数目与训练样本数匹配时，过度训练达到峰值。为理解这一行为，我们计算了图 7E 中隐藏层活动的特征值谱。尽管存在非线性，我们仍看到了与线性情形在定性上相似的行为：小特征值近似遵循 Marchenko–Pastur 分布（参见图 2）。Pennington 与 Worah (2017) 推导了这一协方差矩阵特征值的渐近分布；Pennington 与 Bahri (2017) 也利用对隐藏层小特征值的类似观察，在一个略有不同的背景下研究了训练误差。图 14 给出了不同信噪比下这一过度训练峰值的进一步模拟，表明含噪数据会放大过度训练，使其近似正比于信噪比的倒数增大，这正是式 (13) 所预示的结果。

采用早停时，更大的模型更好。令人瞩目的是，我们没有发现过拟合的证据：就早停时的测试误差而言，更大的模型始终更好。这里的教师网络只有 30 个隐藏神经元，数据集也只有 300 个样本。然而，表现最好的学生模型却是测试过的最大模型，包含 16 326 个隐藏单元，即教师隐藏神经元数的 344 倍，训练样本数的 54 倍。大模型的这一优势要求采用早停和小随机权重初始化，因此反映的是通过限制解的范数而实现的正则化（详见第 7 节的进一步讨论）。如果训练持续更长时间（图 7C 中的绿色曲线），最优模型规模则小于样本数（约为 60 个隐藏单元），与关于模型复杂度的通常直觉一致。我们注意到，在这一设定下，尽管大模型的后期测试误差不会发散到无穷大，但小模型的表现仍然更好，这似乎与近期其他研究中的观察结果相冲突（Belkin、Hsu、Ma 等，2019）。正如第 6 节将讨论的，在我们的设定中，过参数化模型是否比小模型泛化得更好，取决于数据集的信噪比。

译注 原文在此写为“344 倍”，与同时给出的隐藏单元数不一致： $16\,326/30 = 544.2$ 。译文保留原文数字以便对照；按给出的两个网络规模计算，应约为 544 倍。

泛化误差的数学分解 为深入理解这一更复杂的非线性情形，我们将测试误差分解为若干可解释的部分。在第一层冻结、第二层可训练的设定下，泛化误差可分为三个部分：逼近误差、过拟合

误差和零空间误差。这个分解有助于解释，在样本数固定时，改变网络参数数目为何能够改善泛化性能。它也为教师—学生框架如何适用于更现实的场景提供了一种解释：在这些场景中，模型与数据并不属于同一个类别。本质上，最佳可能的神经网络充当了一个有效教师，而标签噪声则吸收了神经网络无法表示的那部分变换。也就是说，从神经网络估计过度训练误差的角度看，逼近误差的行为与外部噪声十分相似。这意味着，即使问题中不存在标签噪声，也可能存在由学生网络架构所决定的有效噪声。

我们可以将两层神经网络写成

$$\hat{y}_a(x) = \sum_{i=1}^{N_h} w_{ai} \phi_i(x). \quad (32)$$

一般而言， ϕ_i 是从输入到隐藏表示的映射，可以是非线性的。这里 $x \in \mathbb{R}^{N_i}$ 、 $y \in \mathbb{R}^{N_o}$ ，且 $\phi_i: \mathbb{R}^{N_i} \rightarrow \mathbb{R}$ 。我们不限定 ϕ_i 的具体选择，但在典型两层网络中，它会具有如下形式： $\phi_i(x) = \sigma(\sum_j J_{ij} x_j)$ ，其中矩阵 J 表示固定的输入层到隐藏层权重。

随后，我们使用一组输入—输出数据 (x^μ, y^μ) ($\mu = 1, \dots, P$) 训练网络；这些数据由某个可以是确定性或随机性的过程生成。假设采用均方误差损失函数，训练误差为

$$E_t = \frac{1}{2} \sum_{a,\mu} \left(y_a^\mu - \sum_{i=1}^{N_h} w_{ai} \phi_i(x^\mu) \right)^2. \quad (33)$$

我们定义隐藏层活动矩阵 $\Phi_{i\mu} = \phi_i(x^\mu)$ ，以及输出矩阵 $Y_{a\mu} = y_a^\mu$ 。

假设输出权重初始为零，则网络在训练后期学得的权重 $\hat{w}$ 为

$$\hat{w} = \hat{R} \hat{C}^\dagger, \quad (34)$$

其中我们定义

$$\hat{R} = Y \Phi^T, \quad \hat{C} = \Phi \Phi^T. \quad (35)$$

对于给定架构，使泛化误差最小的网络权重为

$$w^* = R C^\dagger, \quad (36)$$

其中 $C_{ij} = \langle \phi_i(x) \phi_j(x) \rangle_x$ ， $R_{ai} = \langle y_a(x) \phi_i(x) \rangle_x$ 。

然而，在有限数据上训练时，学生网络的权重只会沿隐藏层协方差非零的方向增长。因此，定义 $w_\parallel^*$ 是有用的：它是在经验隐藏层协方差零空间内权重为零这一约束下，使泛化误差最小的权重。如果把向隐藏层数据所在空间的投影定义为 $P_\parallel = (\Phi \Phi^T)(\Phi \Phi^T)^\dagger$ ，则可以证明

$$w_\parallel^* = R C^\dagger P_\parallel, \quad (37)$$

因此，限制在与数据平行的子空间内时，最佳可能权重就是 w^* 在该子空间上的投影。

译注 式 (37) 的普通正交投影表达在一般总体协方差下需要额外条件（例如 C 与 $P_\parallel$ 对易）；原文后续三项分解也依赖相应正交性。此处保留原式，附录 C 译注给出条件与受限最优解的精确表达。式 (38)、(42) 的第一项在多输出时还应取迹。




图 9 两层网络的泛化误差分解。这里使用由两层教师网络生成的数据，教师采用 ReLU 激活，有 20 个隐藏单元，不含噪声。学生网络的第一层权重随机且固定，同样采用 ReLU 激活。(A) 蓝色为逼近误差，红色为零空间误差，金色为过拟合误差，青色为三者之和。黑色误差条表示使用 5000 个新样本计算的泛化误差。加号表示以 $w_{\parallel}^*$ 为权重的两层教师、并加入高斯噪声时的泛化误差；该噪声的方差与逼近误差和零空间误差之和相匹配。训练样本数为 $P = 50$ （竖直虚线），误差条由 500 次试验计算。(B) 逼近误差（蓝色）、零空间误差（红色）以及两者之和（黑色虚线）。关于本图图例中颜色的解释，读者可参阅本文的网络版。

我们发现，可将泛化误差分解为三项，以解释较晚停止训练时的泛化误差行为：

$$E_g^{\text{late}} = \mathcal{E} \Phi^T (\Phi \Phi^T)^\dagger C (\Phi \Phi^T)^\dagger \Phi \mathcal{E}^T + \text{Tr}[RC^\dagger P_\perp C P_\perp^T C^\dagger R^T] + \langle \epsilon(x)^2 \rangle_x, \quad (38)$$

其中，第一项称为过拟合误差 E_g^{overfit} ，第二项称为零空间误差 E_g^{null} ，第三项称为逼近误差 E_g^{approx} 。我们定义逼近噪声矩阵

$$\mathcal{E}_{i\mu} = Y_{i\mu} - \sum_j w_{ij}^* \Phi_{j\mu}. \quad (39)$$

逼近误差 $\langle \epsilon(x)^2 \rangle_x$ 定义为：给定某一网络架构，通过优化权重能够达到的最小泛化误差。如果相对于待学习的规则，网络过小或过于简单，逼近误差就会很大。

零空间误差可以理解作为一种额外的逼近误差，其原因是在隐藏层活动的零空间中无法发生学习。在本设定中，只有当隐藏单元数超过样本数时，才会出现这种误差。

最后，过拟合误差是由数据集有限这一事实产生的误差；通过经验隐藏层协方差矩阵的特征值分解，它强烈依赖于参数数目与样本数的比值。这一过拟合误差具有很强的非单调性，并可能在样本数与自由参数数目相等的位置，引起泛化误差的巨大峰值。分解计算的详细推导见附录 C。图 9A 绘出了这一分解，并将三项之和与泛化误差作比较。

有趣的是，如果将实际数据替换为一个噪声限制在数据子空间内的模型所生成的新数据，

$$\tilde{y}^\mu = \sum_{j=1}^{N_h} w_{\parallel j}^* \phi_j(x^\mu) + z_a^\mu, \quad (40)$$

其中 $z_a^\mu \sim \mathcal{N}(0, \langle \epsilon_{\parallel}(x)^2 \rangle)$ ，我们会发现，其结果与线性网络计算对过拟合误差及泛化误差的预测十




图 10 标签噪声对宽网络性能的影响。与图 9 一样，绘制泛化误差分解：(A) 欠参数化网络 $N_h = 10$ ；(B) 过参数化网络 $N_h = 200$ 。由于两个网络都加入了输出噪声，即使较大的网络也难以逼近该函数，因为它学习的函数不是确定性的。不过，由于隐藏层协方差的特征值谱，较大网络中的拟合误差更大。这与图 9 所示确定性、低噪声设定下更大网络表现更好的发现不同。其余参数： $P = 50$, $N_t = 20$, $\sigma_w^0 = 0$, $\sigma_w = 1$ 。

分吻合（见图 9A 中的“noisy E_g ”）。这里，有效噪声的方差来自限制在数据子空间内的逼近误差：

$$\langle \epsilon^{\parallel}(x)^2 \rangle = \text{Tr}[RC^{\dagger}P_{\perp}CP_{\perp}^TR^T] + \langle \epsilon(x)^2 \rangle_x. \quad (41)$$

这说明，我们可以将逼近误差视为标签噪声：随着架构增大，它逐渐衰减；直到增加后的参数数目超过训练样本数，受约束的逼近误差才停止下降并开始趋于饱和（见图 9B）。在这种情形下，更宽网络带来的进一步泛化误差改善，并非源于其受约束逼近误差的降低，而是源于经验协方差的特征值谱，因为小特征值与零特征值之间的间隙会随网络宽度增大而扩大。因此，这一分解有助于解释：即使没有正则化或早停，大型神经网络也能够避免过拟合，并在参数多于样本时取得更好的泛化误差。

作一些进一步的修改后，它也有助于理解初始权重和真实标签噪声如何影响不同规模非线性网络的性能。式 (38) 给出了从零初始权重出发、训练到后期时的泛化误差。如果初始权重 $w(0)$ 改为独立同分布地抽取，均值为零、方差为 $(\sigma_w^0)^2$ ，那么对大网络，我们可以对初始化取平均，得到

$$\begin{aligned} E_g^{\text{late}} = & \mathcal{E}\Phi^T(\Phi\Phi^T)^{\dagger}C(\Phi\Phi^T)^{\dagger}\Phi\mathcal{E}^T \\ & + \text{Tr}[RC^{\dagger}P_{\perp}CP_{\perp}^TR^T] \\ & + (\sigma_w^0)^2 \text{Tr}[P_{\perp}CP_{\perp}^T] + \langle \epsilon(x)^2 \rangle_x, \end{aligned} \quad (42)$$

此时，第二项与第三项都可以视为零空间误差的一部分，因为训练过程中这些方向的初始权重保持冻结，所以当 $N_h > P$ 时，较大的初始化尺度会增大泛化误差。此外，独立同分布的标签噪声通过替换 $\langle \epsilon(x)^2 \rangle \rightarrow \langle \epsilon(x)^2 \rangle + \sigma_{\epsilon}^2$ 进入泛化误差。

图 10 展示了标签噪声如何削弱网络架构引起的逼近误差差异的重要性，从而使过拟合误差和隐藏层协方差谱对泛化误差的决定作用更突出。因此，这一设定最接近单层网络动力学。图 11 还展示了，相较于欠参数化网络，初始权重尺度如何对大型过参数化网络的性能产生更大的影响。在这种情形下，零空间误差随初始化方差增大而增长，从而使 $N_h > P$ 时的泛化误差增大。




图 11 初始化对宽网络性能的影响。与图 9 一样，绘制泛化误差分解：(A) 欠参数化网络 $N_h = 10$ ；(B) 过参数化网络 $N_h = 200$ 。结果表明，大尺度初始化会损害过参数化宽神经网络的泛化性能，而不会对较小网络产生这一影响。这一效应来自训练样本少于自由参数时观察到的冻结子空间，也再次不同于图 9 所示小尺度初始化设定下更大网络表现更好的发现。其余参数： $P = 50$ ， $N_t = 20$ ， $\sigma_\epsilon = 0$ ， $\sigma_{\bar{w}} = 1$ 。

5 两层均训练的网络

接下来，我们允许学生网络的两层都参与训练，正如实践中通常所做的那样。图 12 表明，这一设定下也会出现相似的动力学。过度训练是暂态现象，并在中等复杂度处达到峰值，大致对应自由参数数目 ($N_i \cdot N_h + N_h$) 等于样本数 P 的位置。长期训练时，训练误差正是在这一点达到零 (图 12A 中的红色曲线)，这与近期关于 ReLU 网络误差景观的结果一致 (Soudry 与 Hoffer, 2017; Spigler 等, 2018)。关于模型复杂度，我们再次发现，只要正确终止训练并使用小初始权重，相对于教师规模和样本数而言极其庞大的模型实际上是最优的。具体来说，一个具有 34 430 个隐藏神经元的模型取得了良好表现；它的神元数为教师的 1147 倍、样本数的 115 倍。相反，如果不采用早停，本例的长期测试误差在很小的模型复杂度——约 5 个隐藏神经元——处有唯一的最小值。因此，与前面一样，早停使超大模型能够成功泛化，其定性行为与线性情形类似。需要谨慎的是，我们只能期望线性分析近似成立。作为一个明显行为差异的例子，我们注意到，当参数数目等于样本数时，测试误差曲线 (图 12C 中图) 在线性情形和隐藏权重固定的情形下会发散到无穷大 (分别见图 2B 中图和图 7F 中图)，而在两层均训练的情形下似乎趋向一个有限渐近值 (见图 12C 中图)。尽管如此，在预测的峰值处 (自由参数数目与样本数相等时)，这一渐近值仍远大于其他网络规模下的值。

5.1 真实数据集：MNIST

最后，为考察我们的发现能在多大程度上推广到真实数据集，我们使用 MNIST 数据集，在一个数字二分类识别任务上训练非线性网络 (LeCun、Cortes 与 Burges, 1998)。遵循 Louart、Liao 与 Couillet (2017) 的设定，我们训练网络区分 $P = 1024$ 张数字 7 与 9 的图像。每个输入是一幅 28×28 像素的灰度图像，展平为长度 $N_i = 784$ 的向量。输入通过除以 255 缩放到 0 与 1 之间，并将每个分量平移，使其在训练数据集上的均值为零。目标输出根据输入类别取 ± 1 ，损失函数仍然是训练数据集上的均方误差。我们用批量梯度下降训练单隐藏层模型，分别考察固定第一层和两层均训练两种情况。图 13 展示了不同模型规模下，以及采用不同早停时刻时得到的训练误差和测试误差。所有定性特征似乎再次成立：当有效参数数目与样本数匹配时，过度训练达到峰值；更




图 12 训练非线性学生网络的两层。这些模拟采用与图 7 相同的设定，但学生网络的两层都参与训练。自由参数总数等于样本数 ($N_h + N_i N_h = P$) 时的隐藏单元数用虚线标出，与观察到的过度训练峰值很好地对应。关于本图图例中颜色的解释，读者可参阅本文的网络版。




图 13 使用 1024 个训练样本，在 MNIST 数字 7 与 9 的二分类任务上训练两层网络（没有冻结权重）。前面识别出的定性趋势仍然成立：过度训练是在中等复杂度下出现的暂态现象，大模型表现良好；在最优早停下没有观察到过拟合。注意，过度训练不如之前明显，主要是因为计算资源限制使这些实验仅运行了 5000 轮，而图 7 和图 12 中的实验运行了数万轮。

大的模型总体上表现更好。需要指出的是，受计算资源限制，这些实验仅进行了 5000 轮批量梯度下降（相比之下，本文其他实验进行了 7.5 万至 15 万轮），因此过度训练峰值较不明显；最大模型规模也只有 1740，使得过度训练峰值较难辨认，尤其是在第一层固定的情形中。此外，没有出现过拟合的证据，因为最大的模型优于较小模型。总体而言，这些定性发现与学生—教师范式中的结果相当一致，说明我们的分析揭示了通过梯度训练的神经网络中，泛化动力学的一般行为。




图 14 记忆、泛化与信噪比。使用不同信噪比的目标标签训练第一层固定的非线性 ReLU 网络（设定与图 7 相同）。(A–B) 近乎随机的目标标签 ($\text{SNR} = 0.01$)。在模型规模超过样本数的高维区域（此处为 $N_h > 300$ ，以竖直点线标出），只要训练时间足够长，所有网络都能轻易达到零训练误差，因而表现出记忆任意数据集的能力。(C–D) 然而，将这些规模完全相同的模型用于标签近乎无噪声的数据 ($\text{SNR} = 10$) 时，它们又能很好地泛化。事实上，在低噪声区域，模型规模足够大时，甚至连早停也不再必要。只要网络以小权重初始化，梯度下降动力学就会自然地保护泛化性能，因为不含信息的方向上不存在动力学变化。（有关本图题中颜色指代的解释，请参阅本文的网络版。）

6 双下降、插值、记忆与泛化

在训练误差可以降至零的插值区域，Belkin, Hsu, Ma 等 (2019) 以及 Belkin, Hsu 和 Xu (2019) 的重要工作表明，规模很大的模型可以获得比小模型更低的测试误差。对于标签噪声很小的情形，我们在图 9 中也发现了类似行为。不过，需要指出，在本文的设定下，大模型经过充分训练后并不总是表现得更好。图 14 展示了两种信噪比水平下测试误差随模型规模的变化。尽管我们普遍观察到双下降曲线，即训练后期的测试误差随隐层规模呈非单调变化 (Belkin, Hsu, Ma 等, 2019)，但究竟是较小还是较大的模型能够获得更低的测试误差，取决于信噪比。在标签噪声较大的区域 (图 14A–B)，小模型表现更好；而在噪声较小的区域 (图 14C–D)，过参数化模型表现更好。为理解这一差异的来源，我们考察图 10 所示的误差分解：随着噪声增大，小模型和大模型的逼近误差都会增大，因为无论采用何种方式，都无法精确实现一个非确定性的教师。然而，大网络的误差拟合项对总误差的贡献更大，如图 10B 中的金色部分所示。因此，在高噪声区域，经过充分训练后，过参数化模型的泛化表现不如较小的模型。

为了获得良好的泛化性能，模型必须识别数据集背后的规则，而不能只记住每个训练样本的具体细节。检验记忆能力的一种经验方法，是考察深度神经网络能否拟合一个将真实标签随机打乱后的训练集 (Zhang 等, 2017)。如果网络能够拟合任意随机标签，它似乎就能记忆任意训练数据集，因而会具有过大的容量和较差的泛化性能。Zhang 等 (2017) 采用了这一方法，Arpit 等

(2017) 又对此进行了扩展。他们的主要经验发现却与这一朴素解释相冲突：虽然大型深度网络确实很容易在随机标记的数据集上达到零训练误差，但在真实标签上训练时，即使不采用任何正则化或早停，它们依然能够很好地泛化。我们的结果从数据集的信噪比和梯度下降的高维动力学出发，为这些现象给出了一种直接的解释。

在我们的学生-教师设定中，随机标记的训练集对应于输入和输出之间不存在关联规则的情形，可由 $\text{SNR} \rightarrow 0$ 的区域实现。如图 14A 的红色曲线所示，参数多于样本的非线性网络能够轻易地在这个纯噪声数据集上达到零训练误差。然而，在经过大量训练后，甚至在最优早停时，它们都无法很好地泛化，因为模型拟合的是纯噪声。当这些完全相同的网络改为在高信噪比数据集上训练时（图 14C），它们的泛化性能却极好，几乎达到预言机下界。此外，在高信噪比区域，对于规模较大的网络，早停带来的性能收益几乎消失。举一个具体的例子：本文考察的最大网络 ($N_h = 16\,326$) 在低信噪比区域能够轻易拟合噪声标签，而在高信噪比区域，即使完全不采用早停，其泛化性能也优于所有其他模型。这一行为源于高维设定中的两个重要现象。第一，在过完备网络中，梯度下降动力学不会沿没有数据分布的子空间移动。当网络以范数较小的权重初始化时，这个冻结子空间会对网络复杂度产生隐式正则化作用。无论网络有多大，学习动力学中都只有一个 P 维子空间保持活跃。第二，随着过完备程度增大，由于 Marchenko–Pastur 分布的性质，隐层相关矩阵的特征值间隙（最小非零特征值）也会增大，从而在训练时间很长时仍能防止过度训练。特征值间隙随之增大是高维设定的一项基本性质。因此，只要数据集中待学习的规则足够突出、网络规模足够大，而且网络以小权重初始化，大型神经网络即使不采用早停也能很好地泛化。下一节将从 Rademacher 复杂度的角度进一步阐述这一发现。

7 Rademacher 复杂度与非线性神经网络中的过拟合抑制

我们希望理解，为什么传统的 Rademacher 复杂度界在定性上不符合神经网络中观察到的过度训练图景。尤其是，这些界似乎无法解释大型神经网络能够达到的优异泛化性能。为此，我们简要说明如何将梯度下降学习的动力学纳入 Rademacher 复杂度，从而得到一个在直觉上更有助于理解神经网络过度训练的界。我们推导的界有一个特别好的性质：它揭示了不采用早停时也能实现泛化的原因。即使训练持续很长时间，当 $N_h > P$ 时，Rademacher 复杂度仍有望随隐单元数 N_h 的增加而下降。

正如 Zhang 等 (2017) 所指出的，从表面上看，大网络的优异泛化能力似乎与 Rademacher 复杂度和 VC 维等传统度量所提供的直觉相矛盾。我们发现，直接使用这些度量，不仅会得到宽松的界，甚至还会得出与模拟结果相反的定性行为。

图 7C 给出了一个简单例子，其中的任务是拟合一个随机非线性教师。在这里，学生网络的规模增大到远超数据集中的样本数以及教师网络的隐单元数之后，早停时的泛化性能依然持续改善。正如 Zhang 等 (2017) 所讨论的，由于更大的神经网络更容易拟合随机标记的数据，网络的 Rademacher 复杂度和 VC 维会随隐单元数增加而增大。如果考虑训练一个第一层随机的大型非线性神经网络，那么分类问题的经验 Rademacher 复杂度（例如，参见 Mohri, Rostamizadeh 和 Talwalkar, 2012）为

$$\mathcal{R}(\mathcal{H}) = \left\langle \sup_{h \in \mathcal{H}} \frac{1}{P} \sum_{\mu=1}^P \sigma^\mu h(x^\mu) \right\rangle_{\sigma, x}. \quad (43)$$

其中， $\mathcal{H}$ 是网络或分类器可以实现的函数类，这些函数将输入 x^μ 映射为输出； $\sigma^\mu = \pm 1$ 是随机选择的标签。Rademacher 复杂度衡量网络学习随机标签的能力，并给出新样本与训练样本的正确

分类概率之差的界；原文在下文将对对应量分别称为泛化误差和训练误差。该界表明，以至少 $1 - \delta$ 的概率有

$$E_g - E_t \leq 2\mathcal{R}(\mathcal{H}) + \sqrt{\frac{\log(1/\delta)}{2P}}. \quad (44)$$

译注 原文在上述一句中使用了“正确分类概率”一词，随后却以“误差”命名。式 (44) 应按泛化误差 E_g 与训练误差 E_t 的差来理解。另需区分式 (43) 中对随机标签和样本共同取平均的复杂度，与将训练样本固定后仅对随机符号取平均的经验复杂度；原文将前者也称为“经验 Rademacher 复杂度”。

随着大型随机网络的宽度增加，我们在实验中看到，能够被精确拟合的数据点数也会随网络规模增大。因此，当 $N_h > P$ 时，上述界变得平凡，因为在这一极限下 $\mathcal{R}(\mathcal{H}) \geq O(1)$ ，而且任意随机分类都可以实现：求解最后一层的权重，只需要用 P 个随机约束方程求解 N_h 个未知数。这一论证表明该界很宽松，但对于最坏情形分析而言，这一点并不意外。更令人意外的是定性行为上的差异：在我们的模拟中，较大的网络在避免过度训练方面实际上优于中等规模的网络。

不过，我们将看到，如果利用宽网络的学习动力学对 Rademacher 复杂度作更细致的上界估计，确实能够刻画我们在实践中观察到的过度训练行为。对于具有一个隐层的整流线性网络，Rademacher 复杂度的一个界 (Bartlett 和 Mendelson, 2002) 为

$$\mathcal{R}(\mathcal{H}) \leq \frac{B_2 B_1 C \sqrt{N_h}}{\sqrt{P}}. \quad (45)$$

其中， B_2 是输出权重的范数， B_1 是各隐神经元输入权重的 L^2 范数的最大值， C 是输入数据范数的最大值。由此可见，无论隐神经元有多少，都可以通过减小第二层的权重范数来控制假设类的复杂度。

早停和 L^2 正则化都能限制第二层权重的大小，从而减少过拟合；我们的模拟也观察到了这一点。采用早停时，动力学会依次经过范数更大、表达能力更强的模型，而早停用于选取适当的复杂度。

然而，一个值得关注的结果是，即使不采用早停，我们的解析解依然能够通过隐层的特征值谱给出第二层权重的界。其基本直觉有两点：第一，当模型处于高度过完备状态时，存在一个很大的冻结子空间；由于没有训练样本位于这些方向，学习不会在其中发生。第二，最小特征值与零之间的特征值间隙增大，从而防止过度训练，并限制权重整体的增长。为了推导出计入这些事实的 Rademacher 复杂度新界，我们在本文的表述下，解析考察权重范数对训练时间的依赖。在所考虑的非线性且第一层随机固定的设定中，模型为

$$\hat{y}(x) = \sum_{a=1}^{N_h} \frac{w_a}{\sqrt{N_h}} \phi_a(x). \quad (46)$$

由于与单层情形相似，这里稍微借用一下记号，令 $X_h^{a\mu} = N_h^{-1/2} \phi_a(W_a^1 \cdot x^\mu)$ 。随后将隐层协方差矩阵对角化，使 $X_h(X_h)^T = V_h \Lambda_h V_h^T$ ，再求解权重的动力学，得到

$$z_i^h(t) = \frac{\tilde{z}_i^h}{\lambda_i^h} \left(1 - e^{-\lambda_i^h t / \tau}\right) + z_i^h(0) e^{-\lambda_i^h t / \tau}. \quad (47)$$

这里定义向量 $z^h = w V_h^T$ 、 $\tilde{z}^h = y(X_h)^T V_h$ ，以及 $z_i^h(0) = w(0) V_h^T$ ，并将隐层协方差矩阵的特征值记

为 $\lambda_1^h, \dots, \lambda_{N_h}^h$ 。因此，输出层权重的平均平方范数为

$$\begin{aligned}\langle \|w(t)\|^2 \rangle &= \sum_i z_i^2(t) \\ &= \sum_i \left[\frac{\|z_i^h\|^2}{(\lambda_i^h)^2} \left(1 - e^{-\lambda_i^h t / \tau}\right)^2 + \|z_i^h(0)\|^2 e^{-2\lambda_i^h t / \tau} \right].\end{aligned}\quad (48)$$

对于没有隐层的浅层线性网络，权重范数增长的表达式非常相似，只需代入 $\tilde{z}_i^h = \bar{z}_i^h + \tilde{\epsilon}_i / \sqrt{\lambda_i^h}$ ；此时，在高维极限下，特征值的分布趋于 Marchenko–Pastur 分布。

译注 本段保留了原文的记号，但复算时需注意几处不一致。若按 $X_h(X_h)^T = V_h \Lambda_h V_h^T$ 并将权重写为行向量，旋转坐标应取 $z^h = w V_h$ ，初值相应为 $z^h(0) = w(0) V_h$ ；原文既多写了转置，也将初值向量误写成单个分量 $z_i^h(0)$ 。式 (48) 中交叉项的消失，需要对独立、零均值的随机初始化等变量取平均，或采用下文的零初始化；对任意固定初值，该交叉项一般不为零。按式 (47) 的定义，线性情形的代换应理解为 $\tilde{z}_i^h / \lambda_i^h = \bar{z}_i^h + \tilde{\epsilon}_i / \sqrt{\lambda_i^h}$ 。式 (47) 及含 $1/\lambda_i^h$ 的表达式按非零特征值方向理解，零特征值方向直接由冻结动力学处理。

现在假设初始权重为零 ($\sigma_w^0 = 0$)，因为这种设定会使误差最小，而我们的大规模模拟也接近这一极限（注意，在深度网络中，初始权重不能精确设为零，否则学习动力学会被冻结）。由此可知， $\langle \|w(t)\|^2 \rangle$ 会随时间单调增加，这意味着 Rademacher 复杂度界也随时间增加。

最小非零特征值限制了权重范数所能达到的最大值；零特征值不会产生动力学变化，因此不会影响权重范数。于是，即使不采用早停，我们仍可在 P, N_h 很大的极限下，通过式 (48) 的长时间行为的上界来限制权重范数：

$$\frac{\|w\|}{\sqrt{N_h}} \leq \sqrt{\frac{\max_i \|z_i^h\|^2}{\min_{i, \lambda_i^h > 0} (\lambda_i^h)^2} \frac{\min(P, N_h)}{N_h}} = B_2. \quad (49)$$

这里出现 P 和 N_h 的最小值，是因为值为零的特征值对应冻结子空间，对学习没有影响。分母中出现最小特征值，表明随着特征值间隙增大，这个界会改善。将其代入式 (45)，即可得到一个用隐层特征值谱表示的 Rademacher 复杂度界：

$$\mathcal{R}(\mathcal{H}) \leq B_1 C \sqrt{\frac{\max_i \|z_i^h\|^2}{\min_{i, \lambda_i^h > 0} (\lambda_i^h)^2} \frac{\min(P, N_h)}{P}}. \quad (50)$$

上述界在定性上符合第一层权重固定的非线性网络模拟结果。模拟表明，当网络参数数目增大并超过样本数时，较晚停止训练所得的训练误差与泛化误差之间的差距会缩小（见图 7C–D）。在上述各式中，当 N_h 增大到超过 P 时， $\min(P, N_h)$ 始终固定为 P ，但隐层协方差矩阵的最小非零特征值确实会增大（例如，见图 7E）。因此，在高度过完备网络中，这一特征值谱间隙能够通过限制网络权重所能达到的大小，降低 Rademacher 复杂度。

译注 式 (49) 中的 B_2 对应式 (46) 实际输出系数 $w_a / \sqrt{N_h}$ 的范数上界。原文在引入式 (49) 时称其为“隐层中的权重”，但此处随训练变化并被约束的是输出层权重；第一层权重仍然固定。

8 讨论

我们的结果表明，在高维区域，梯度下降学习动力学的共同作用能够使模型在规模很大的情况下，依然获得可接受的泛化性能。将网络做得非常大，即使其自由参数多于数据集中的样本，也能够减轻过度训练，因为网络中的许多方向具有零梯度，因而从未被学习。无论是否提前停止学习，这个冻结子空间都能防止过度训练。过度训练最严重的情形是：对于浅层网络，网络宽度与样本数相匹配；对于非线性随机网络，参数数目与样本数相匹配。因此，我们对学习动力学的分析，有助于解释为什么在非常大的网络中，过度训练并不是一个严重问题。

此外，我们表明，将非线性两层网络做得非常大，无论第一层是随机固定的，还是也参与训练，都能够持续改善泛化性能，尽管深度网络具有很高的 Rademacher 复杂度 (Zhang 等, 2017)。我们在向随机教师学习的任务和 MNIST 分类任务中，都展示了这一效应。

我们的发现来自随机矩阵理论的预测：当样本数与参数数目相匹配时，小特征值会更加丰富。在欠完备或过完备区域，由于输入相关矩阵的最小非零特征值与原点之间存在间隙，学习会表现良好。在分析中，我们采用了一个简化设定，假设输入、真实参数和噪声都服从高斯分布。不过，对参数和噪声的高斯假设并非必需；只需它们是独立同分布抽样，并具有有限的均值和方差即可。对于其他输入分布，我们已经通过实验表明，本文结果适用于 MNIST 数据集。更一般地，对于元素独立同分布、来自具有次指数尾的非高斯分布的随机矩阵，Marchenko–Pastur 分布是其特征值分布的一个普适极限（例如，参见 Pillai, Yin 等, 2014）。因此，当噪声、参数和输入均从非重尾分布中独立同分布地选取时，这些预测具有理论依据。我们指出，这种普适性的确切适用范围仍是当前研究的主题；特别是，具有强相关性的输入分布可能产生很大的偏离。

最后，我们的分析指出了若干实践者能够控制、并会影响泛化性能的因素。要给出实践建议，就必须理解表现优异的深度网络通常处于什么区域。我们认为，相关区域是高维、高信噪比设定 ($\alpha < 1$, $\text{SNR} \gg 1$)。在这一区域，非常大的网络具有显著优势：即使不采用任何正则化或早停，它们的泛化表现也优于规模较小的网络（参见图 14）。例如，考虑图 13 所示的 MNIST 数据集结果。在这里，尽管早停可以提高性能，但即使训练时间很长，表现最好的模型仍然是所测试的最大模型。对于这一设定，我们的理论带来的实践启示是：只要以较小的初始权重初始化，更大的模型从泛化角度看就没有不利之处。我们的结果表明，在数据有限而网络很大的区域，初始化会对泛化误差产生强烈影响：无论训练是否采用早停，从小权重开始对于获得良好的泛化性能都至关重要。

除深度线性网络的约化外，我们的结果主要针对深度很小、至多只有一个隐层的网络。这些发现如何推广到更深的非线性网络 (Kadmon 和 Sompolinsky, 2016)，以及在很深的网络中，良好泛化所需的条件（小权重）是否会与快速训练所需的条件（大权重；Saxe 等, 2014）相冲突，仍有待研究。

自本文最初的预印本发布以来，近期的一些工作也考察了类似思想（综述见 Bahri 等, 2020）。特别是，Spigler 等 (2018) 使用合页损失训练更深的网络，并观察到了与本文类似的经验发现：当样本数接近神经网络的有效参数数目时，过度训练最为严重。关于“双下降”现象，也已有进一步研究 (Belkin, Hsu, Ma 等, 2019; Belkin, Hsu 和 Xu, 2019)，包括对现代最先进深度学习模型的研究 (Nakkiran 等, 2020)；与此同时，越来越多的论文提供了能够精确分析双下降的设定 (Ba, Erdogdu, Suzuki, Wu 和 Zhang, 2019; Bartlett, Long, Lugosi 和 Tsigler, 2020; Belkin, Hsu 和 Xu, 2019; Hastie, Montanari, Rosset 和 Tibshirani, 2019)。例如，Hastie 等 (2019) 在非线性的设定中对无岭回归进行了统计分析，这对应于本文分析中训练时间趋于无穷的情形。Ba 等 (2019) 则超越了从固定非线性变换中学习读出权重的设定，在只训练第一层权重矩阵的学生-教师框架下，考察

了不同初始化区域中的渐近性能。另一些研究使用随机矩阵理论的工具，考察了比本文简单高斯假设更复杂的输入统计特性，包括聚类输入的影响 (Louart 等, 2017)，以及由随机非线性变换产生的特征 (Pennington 和 Worah, 2017)。

已有结果表明，无限宽网络可以在“主动”或“惰性”区域中训练 (Chizat, Oyallon 和 Bach, 2018)，这突出了初始化在控制深度网络归纳偏置方面的重要性。在对应较大初始化的惰性区域中，深度非线性网络的动力学按一个线性系统演化，其特征由神经切线核决定 (Arora, Du, Hu, Li 和 Wang, 2019; Jacot, Gabriel 和 Hongler, 2018; Lee 等, 2019)。这表明，冻结子空间的思想可以直接推广到这一设定。然而，在主动区域中，动力学仍然是非线性的，可能与上述线性化行为显著不同，而且通常能达到更好的性能 (Chizat 等, 2018; Mei, Montanari 和 Nguyen, 2018)；因此，从理论上理解深度神经网络的泛化性质，仍然面临挑战。

利益冲突声明

作者声明，他们不存在任何已知的、可能被认为会影响本文所报告工作的竞争性经济利益或私人关系。

致谢

我们感谢 Kenyon Tsai、James Fitzgerald 和 Pankaj Metha 与我们进行了许多有益的讨论。M.A. 和 A.M.S. 衷心感谢哈佛大学理论神经科学 Swartz 项目的支持。A.M.S. 获得英国 Wellcome Trust 与英国 Royal Society 的 Sir Henry Dale Fellowship 资助（项目编号 216386/Z/19/Z）。H.S. 的部分研究获得英国 Gatsby Charitable Foundation 的支持。

附录 A 深层线性神经网络的动力学

这里推导描述深层线性神经网络学习动力学的降维形式。首先作如下变量变换： $W_1(t) = r_2 z(t) V^T$ ，其中 $z(t) \in \mathbb{R}^{1 \times N_i}$ 是一个向量，编码网络与输入各主轴之间随时间变化的重叠量（回顾 $\Sigma^{xx} = V \Lambda V^T$ ）；并令 $W_l(t) = d(t) r_{l+1} r_l^T$ ， $l = 2, \dots, D$ 。向量 r_l 是相应层维数下任意的单位范数向量（ $r_l^T r_l = 1$ ），表示网络内部表征的自由度；定义 $r_{D+1} = 1$ ，标量 $d(t)$ 则编码表征随时间的变化。按照这些定义，

$$W^{\text{tot}} = \left(\prod_{l=2}^D d(t) r_{l+1} r_l^T \right) r_2 z(t) V^T = d(t)^{D-1} z(t) V^T = u(t) z(t) V^T,$$

其中定义了标量 $u(t) = d(t)^{D-1}$ 。

因此，对于 $l > 1$ ，有

$$\tau \frac{d}{dt} W_l = \left(\prod_{i=l+1}^D W_i \right)^T \left[\Sigma^{yx} - \left(\prod_{i=1}^D W_i \right) \Sigma^{xx} \right] \left(\prod_{i=1}^{l-1} W_i \right)^T, \quad (51)$$

$$\begin{aligned} \tau \frac{d}{dt} [d(t) r_{l+1} r_l^T] &= r_{l+1} d(t)^{D-l} [\Sigma^{yx} - d(t)^{D-1} z(t) V^T V \Lambda V^T] \\ &\quad \times V d(t)^{l-2} z(t)^T r_l^T, \end{aligned} \quad (52)$$

$$\tau \frac{d}{dt} [d(t) r_{l+1} r_l^T] = d(t)^{D-2} [\tilde{s} z^T - d(t)^{D-1} z(t) \Lambda z(t)^T] r_{l+1} r_l^T. \quad (53)$$

比较系数，便得到所需的动力学方程

$$\tau \frac{d}{dt} d(t) = d(t)^{D-2} [\tilde{s} z^T - d(t)^{D-1} z(t) \Lambda z(t)^T]. \quad (54)$$

接着变换变量 $u(t) = d(t)^{D-1}$ ，得到第一个微分方程：

$$\tau \dot{u} = (D-1) u^{\frac{2D-4}{D-1}} (\tilde{s} z^T - u z \Lambda z^T). \quad (55)$$

类似地，对于 $l = 1$ ，有

$$\tau \frac{d}{dt} W_1 = \left(\prod_{i=2}^D W_i \right)^T \left[\Sigma^{yx} - \left(\prod_{i=1}^D W_i \right) \Sigma^{xx} \right], \quad (56)$$

$$\tau \frac{d}{dt} [r_2 z(t) V^T] = r_2 d(t)^{D-1} [\Sigma^{yx} - d(t)^{D-1} z(t) V^T V \Lambda V^T], \quad (57)$$

$$\tau \frac{d}{dt} [r_2 z(t) V^T] = d(t)^{D-1} [\tilde{s} - d(t)^{D-1} z(t) \Lambda] V^T. \quad (58)$$

再次比较系数，并代入 $u(t) = d(t)^{D-1}$ ，得到

$$\tau \dot{z} = u (\tilde{s} - u z \Lambda). \quad (59)$$

译注 原文式 (58) 右端漏写了左乘因子 r_2 ；从式 (57) 或矩阵维数均可确认这一点。本译文保留式 (58) 的原貌；在右端补上 r_2 后，才能消去两端共同的 r_2 与 V^T ，得到式 (59)。此外，原文首段将向量下标 i 与层宽下标 l 混用；这里按 r_l 的相应层维数表述。矩阵连乘沿用原文记法，实际次序是从高层到低层，例如 $\prod_{i=1}^D W_i = W_D \cdots W_1$ 。

附录 B 最优权重范数随信噪比的增长

这里推导最优权重范数与信噪比的函数关系，即正文的式 (19)。我们分析正则化强度为 $\gamma = 1/\text{SNR}$ 的岭回归：

$$\hat{w} = yX^T \left(XX^T + \frac{1}{\text{SNR}} I \right)^\dagger. \quad (60)$$

代入模型关系

$$y = \bar{w}X + \epsilon, \quad (61)$$

得到

$$\hat{w} = \left(\bar{w}XX^T + \epsilon X^T \right) \left(XX^T + \frac{1}{\text{SNR}} I \right)^\dagger. \quad (62)$$

利用分解

$$XX^T = V\Lambda V^T, \quad (63)$$

$$X = V\Lambda^{1/2}U^T, \quad (64)$$

上式可以写成

$$\hat{w}V = \left(\bar{w}V\Lambda + \epsilon U\sqrt{\Lambda} \right) (\Lambda + \gamma I)^{-1}. \quad (65)$$

由于噪声和参数值均为独立同分布抽样，旋转 U 和 V 不改变它们的均值或相关矩。因此，可以将上式平方并取平均，计算平均参数强度：

$$\langle \hat{w}^2 \rangle = \sigma_w^2 \frac{1}{N} \sum_{i=1}^N \frac{\lambda_i}{\lambda_i + \frac{1}{\text{SNR}}} \longrightarrow \sigma_w^2 \int \rho^{\text{MP}}(\lambda) \left(\frac{\lambda}{\lambda + \frac{1}{\text{SNR}}} \right) d\lambda. \quad (66)$$

由此可见，所估计参数的平均范数随信噪比单调增加。这与直觉一致：数据质量越高，所需的正则化就越弱。

译注 式 (66) 沿用原文的简写： $\langle \hat{w}^2 \rangle$ 指按输入维度归一化的平均平方范数，即 $N^{-1} \langle \|\hat{w}\|_2^2 \rangle$ ，不是总平方范数。原文积分省略了微分元，此处补写 $d\lambda$ 。这里旋转保持二阶矩所用的是前文零均值、各向同性的独立同分布模型；一般非高斯分布的所有高阶矩并不都具有旋转不变性。

附录 C 泛化误差的分解

首先定义 $w_{\parallel}^*$ ：对于给定的网络架构，在权重沿隐层协方差零空间的分量必须为零的约束下，它使泛化误差最小。对这一约束下的泛化误差进行优化，得到

$$w_{\parallel}^* = RC^\dagger P_{\parallel}. \quad (67)$$

于是可以定义平行子空间中的逼近噪声:

$$\epsilon_{\parallel}(x) = y(x) - w_{\parallel}^* \phi(x). \quad (68)$$

由 $w_{\parallel}^*$ 的定义可得

$$\left\langle \epsilon_{\parallel}^a(x) (u \cdot \phi(x)) \right\rangle = 0 \quad \forall a, \quad (69)$$

其中 u 不在 $\widehat{C}$ 的零空间中。这个事实将使泛化误差表达式中的交叉项得以简化。首先把训练数据分解为一个可实现分量和逼近噪声:

$$Y = w_{\parallel}^* \Phi + \mathcal{E}, \quad (70)$$

其中 $Y_{a\mu} = y_a(x^\mu)$ 、 $\Phi_{j\mu} = \phi_j(x^\mu)$ ，以及 $\mathcal{E}_{a\mu} = \epsilon_a(x^\mu)$ 。由式 (70) 及 $\widehat{w}$ 的表达式，得到

$$\widehat{w} = w_{\parallel}^* + \mathcal{E} \Phi^T (\Phi \Phi^T)^{\dagger}. \quad (71)$$

译注 式 (69) 在原稿中确实没有等号及右端；下文消去交叉项所需的本意应是该平均值“= 0”，且应要求 $u \in \text{range}(\widehat{C})$ ，而不只是“不在零空间中”。此处保留原式以便核对。更实质的限制是：对于一般总体协方差 C ，式 (67) 给出的欧氏投影 $RC^{\dagger}P_{\parallel}$ 未必是受限的总体风险最优解。若 Q 的列为数据子空间的标准正交基，则该受限问题的一个最小范数解为

$$RQ(Q^T C Q)^{\dagger} Q^T.$$

例如在 C 与 $P_{\parallel}$ 对易时，它可化为原文式 (67) 的形式。一般情况下，不能仅由式 (67) 推出式 (69) 的总体正交性，因此下面式 (74) 与 (75) 中交叉项的消失也需要这一额外前提。本译文保留作者的推导，并将此限制与原论文结论分开标明。

泛化误差具有如下形式:

$$E_g = \left\langle \sum_a \left(\sum_j \widehat{w}_{aj} \phi_j(x) - y_a(x) \right)^2 \right\rangle_x, \quad (72)$$

也可以写成

$$E_g = \left\langle \sum_a \left(\sum_j (\widehat{w}_{aj} - (w_{\parallel}^*)_{aj}) \phi_j(x) - \epsilon_{\parallel}^a(x) \right)^2 \right\rangle_x. \quad (73)$$

将平均值展开为三项。对于每个 a ， $\widehat{w} - w_{\parallel}^*$ 都必定位于平行子空间中，因而交叉项为零。于是有

$$E_g = (\widehat{w} - w_{\parallel}^*) C (\widehat{w} - w_{\parallel}^*)^T + \sum_a \left\langle \epsilon_{\parallel}^a(x)^2 \right\rangle. \quad (74)$$

将式 (71) 中的 $\widehat{w}$ 代入上式，得到

$$E_g = \mathcal{E} \Phi^T (\Phi \Phi^T)^{\dagger} C (\Phi \Phi^T)^{\dagger} \Phi \mathcal{E}^T + \sum_a \left\langle \epsilon_{\parallel}^a(x)^2 \right\rangle. \quad (75)$$

译注 式 (70) 后原文将 $\mathcal{E}_{a\mu}$ 写作 $\epsilon_a(x^\mu)$ 。结合式 (68) 和 (70)，这里应理解为 $\epsilon_{\parallel}^a(x^\mu)$ ；由于 $P_{\parallel}\Phi = \Phi$ ，原文投影定义下它与训练样本上的未受限残差相同。式 (74)、(75) 保留原稿形式，但多输出时第一项为 $N_o \times N_o$ 矩阵，必须再取 Tr 才与左端的总标量误差相符；标量输出时不需要取迹。式 (72) 原稿在 $y_a(x)$ 后多出一个逗号，此处作为排印标点删去。

为简化记号，以下在 ϵ 和 $\epsilon_{\parallel}$ 的表达式中省略下标 a ，于是有

$$\begin{aligned}\langle \epsilon_{\parallel}(x)^2 \rangle_x &= \left\langle (y - w_{\parallel}^* \phi(x))^2 \right\rangle \\ &= \left\langle (y - RC^{\dagger} P_{\parallel} \phi(x))^2 \right\rangle.\end{aligned}\quad (76)$$

因此，

$$\langle \epsilon_{\parallel}(x)^2 \rangle_x = \left\langle (y - RC^{\dagger} \phi(x) + RC^{\dagger} (I - P_{\parallel}) \phi(x))^2 \right\rangle. \quad (77)$$

利用 ϕ 与 ϵ 的正交性，可以展开为

$$\begin{aligned}\langle \epsilon_{\parallel}(x)^2 \rangle_x &= \langle \epsilon(x)^2 \rangle_x \\ &\quad + \left\langle \phi(x)^T (I - P_{\parallel})^T C^{\dagger} R^T RC^{\dagger} (I - P_{\parallel}) \phi(x) \right\rangle.\end{aligned}\quad (78)$$

于是得到

$$\langle \epsilon_{\parallel}(x)^2 \rangle_x = \langle \epsilon(x)^2 \rangle_x + \text{Tr} [RC^{\dagger} P_{\perp} C P_{\perp}^T C^{\dagger} R^T]. \quad (79)$$

第二项正是将最优权重投影到正交子空间所造成的泛化误差。注意，对于标量输出，无须取迹。更一般地，若存在非零的初始化权重，则它们会与上式第二项中的 $RC^{\dagger}$ 一起出现；该项就是冻结子空间近似所产生的误差。

参考文献

- Advani, M., & Ganguli, S. (2016a). An equivalence between high dimensional bayes optimal inference and m-estimation. *Advances in Neural Information Processing Systems*.
- Advani, M., & Ganguli, S. (2016b). Statistical mechanics of high dimensional inference supplementary material. In: See <https://ganguli-gang.stanford.edu/pdf/HighDimInf.Supp.pdf>.
- Advani, M., & Ganguli, S. (2016c). Statistical mechanics of optimal convex inference in high dimensions. *Physical Review X*, 6(3), Article 031034.
- Advani, M., Lahiri, S., & Ganguli, S. (2013). Statistical mechanics of complex neural systems and high dimensional data. *Journal of Statistical Mechanics: Theory and Experiment*, (03), P03014.
- Amari, S., Murata, N., & Müller, K. R. (1996). Statistical theory of overtraining - Is cross-validation asymptotically effective?. *Advances in Neural Information Processing Systems*.
- Amari, S., Murata, N., Müller, K. R., Finke, M., & Yang, H. (1995). Asymptotic statistical theory of overtraining and Cross Validation. *IEEE Transactions on Neural Networks*, 8(5), 985–996.
- Arora, S., Cohen, N., & Hazan, E. (2018). On the optimization of deep networks: Implicit acceleration by overparameterization. In *35th international conference on machine learning, ICML 2018, Vol. 1* (pp. 372–389).
- Arora, S., Du, S. S., Hu, W., Li, Z., & Wang, R. (2019). Fine-grained analysis of optimization and generalization for overparameterized two-layer neural networks. In *36th international conference on machine learning* (pp. 477–502).
- Arpit, D., Jastrz, S., Kanwal, M. S., Maharaj, T., Fischer, A., Courville, A., et al. (2017). A closer look at memorization in deep Networks. In *ICML*.
- Ba, J., Erdogdu, M. A., Suzuki, T., Wu, D., & Zhang, T. (2019). Generalization of two-layer Neural networks:an asymptotic Viewpoint. In *International conference on learning representations*. 2016.
- Bahri, Y., Kadmon, J., Pennington, J., Schoenholz, S. S., Sohl-Dickstein, J., & Ganguli, S. (2020). Statistical mechanics of deep learning. *Annual Review of Condensed Matter Physics*, 11(1), 501–528.
- Bai, Z., & Silverstein, J. W. (2010). *Spectral analysis of large dimensional random matrices*. Springer.
- Baldi, P., & Chauvin, Y. (1991). Temporal evolution of Generalization during Learning in Linear networks. *Neural Computation*, 3, 589–603.
- Baldi, P., Chauvin, Y., & Hornik, K. (1990). Supervised and unsupervised learning in Linear Networks. In *International neural network conference* (pp. 825–828).
- Baldi, P., & Hornik, K. (1989). Neural networks and principal component analysis: Learning from examples without local minima. *Neural Networks*, 2(1), 53–58.
- Baldi, P. F., & Hornik, K. (1995). Learning in linear neural networks: a survey. *IEEE Transactions on Neural Networks*, 6(4), 837–858.
- Barron, A. R. (1993). Universal approximation bounds for superpositions of a sigmoidal function. *IEEE Transactions on Information Theory*, 39(3), 930–945.
- Bartlett, P. L., Long, P. M., Lugosi, A., & Tsigler, G. (2020). Benign overfitting in linear regression. *Proceedings of the National Academy of Sciences*.

- Bartlett, P. L., & Mendelson, S. (2002). Rademacher and Gaussian complexities: Risk bounds and structural results. *Journal of Machine Learning Research*, 3(3), 463–482.
- Belkin, M., Hsu, D., Ma, S., & Mandal, S. (2019). Reconciling modern machine-learning practice and the classical bias–variance trade-off. *Proceedings of the National Academy of Sciences*, 116(32), 15849–15854.
- Belkin, M., Hsu, D., & Xu, J. (2019). Two models of double descent for weak features. *arXiv preprint arXiv:1903.07571*.
- Benaych-Georges, F., & Rao, R. (2011). The eigenvalues and eigenvectors of finite, low rank perturbations of large random matrices. *Advances in Mathematics*, 227(1), 494–521.
- Benaych-Georges, F., & Rao, R. (2012). The singular values and vectors of low rank perturbations of large rectangular random matrices. *Journal of Multivariate Analysis*, 111, 120–135.
- Biehl, M., Caticha, N., & Riegler, P. (2009). Statistical mechanics of on-line learning. In T. Villmann, M. Biehl, B. Hammer, & M. Verleysen (Eds.), *Similarity-based clustering: recent developments and biomedical applications*. Berlin Heidelberg: Springer.
- Canziani, A., Paszke, A., & Culurciello, E. (2017). An analysis of deep neural network models for practical applications. (pp. 1–7). In: *arXiv*.
- Caruana, R., Lawrence, S., & Giles, C. L. (2001). Overfitting in neural nets: Backpropagation, conjugate gradient, and early stopping. In *Advances in neural information processing systems* (pp. 402–408).
- Chauvin, Y. (1990). Generalization dynamics in LMS Trained linear networks. In *NIPS* (pp. 890–896).
- Chizat, L., Oyallon, E., & Bach, F. (2018). On lazy training in differentiable programming. In *NeurIPS*.
- Dodier, R. (1995). Geometry of early stopping in Linear Networks. In *Advances in neural information processing systems* 8.
- Du, S. S., Hu, W., & Lee, J. D. (2018). Algorithmic regularization in learning deep homogeneous models: Layers are automatically balanced. *Advances in Neural Information Processing Systems, (NeurIPS)*, 384–395.
- Dunmur, A. P., & Wallace, D. J. (1999). Learning and generalization in a linear perceptron stochastically trained with noisy data. *Journal of Physics A: Mathematical and General*, 26(21), 5767–5779.
- Engel, A., & Van Den Broeck, C. (2001). *Statistical mechanics of learning*. Cambridge: Cambridge University Press.
- Fukumizu, K. (1998). Effect of batch learning in multilayer neural networks. In *Proceedings of the 5th international conference on neural information processing* (pp. 67–70).
- Goodfellow, I. J., Vinyals, O., & Saxe, A. M. (2015). Qualitatively characterizing Neural Network Optimization problems. In *The international conference on learning representations*. San Diego, CA: Oral presentation.
- Hastie, T., Montanari, A., Rosset, S., & Tibshirani, R. J. (2019). Surprises in high-dimensional ridgeless least squares interpolation. *arXiv preprint arXiv: 1903.08560*.
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Delving deep into rectifiers: Surpassing human-level performance on imagenet classification. In *ICCV* (pp. 1026–1034).
- Hoyle, D. C., & Rattray, M. (2007). Statistical mechanics of learning multiple orthogonal signals: Asymptotic theory and fluctuation effects. *Physical Review E*, 75.

- Jacot, A., Gabriel, F., & Hongler, C. (2018). Neural tangent kernel: Convergence and generalization in neural networks. *Advances in Neural Information Processing Systems*, (4), 8571–8580.
- Ji, Z., & Telgarsky, M. (2019). Gradient descent Aligns the Layers of deep Linear Networks. In *International conference on learning representations*.
- Kadmon, J., & Sompolinsky, H. (2016). Optimal architectures in a solvable model of deep networks. In *NIPS*.
- Kawaguchi, Kenji (2016). Deep learning without Poor Local Minima. In *NIPS*.
- Kinouchi, O., & Caticha, N. (1995). On-line versus off-line learning in the linear perceptron: A comparative study. *Physical Review E*, 52(3).
- Krogh, A., & Hertz, J. A. (1992). Generalization in a linear perceptron in the presence of noise. *Journal of Physics A: Mathematical and General*, 25, 1135–1147.
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521, 436–444.
- LeCun, Y., Cortes, C., & Burges, C. J. C. (1998). The MNIST database of handwritten digits.
- LeCun, Y., Kanter, I., & Solla, S. A. (1991). Eigenvalues of covariance matrices: Application to neural-network learning. *Physical Review Letters*, 66(18), 2396.
- Lee, J., Xiao, L., Schoenholz, S. S., Bahri, Y., Novak, R., Sohl-Dickstein, J., et al. (2019). Wide Neural Networks of any Depth evolve as linear models under gradient descent. In *NeurIPS*.
- Louart, C., Liao, Z., & Couillet, R. (2017). A random matrix approach to neural networks. *arXiv preprint arXiv:1702.05419*.
- Marchenko, V. A., & Pastur, L. A. (1967). Distribution of eigenvalues for some sets of random matrices. *Matematicheskii Sbornik*, 114, 507–536.
- Mei, S., Montanari, A., & Nguyen, P. M. (2018). A mean field view of the landscape of two-layer neural networks. *Proceedings of the National Academy of Sciences*, 115(33), E7665–E7671.
- Mishkin, D., & Matas, J. (2016). All you need is a good init. In *ICLR* (pp. 1–13).
- Mohri, M., Rostamizadeh, A., & Talwalkar, A. (2012). *Foundations of machine learning*. MIT press.
- Nakkiran, P., Kaplun, G., Bansal, Y., Yang, T., Barak, B., & Sutskever, I. (2020). Deep double descent: Where Bigger Models and more data Hurt. In *International conference on learning representations*.
- Pennington, J., & Bahri, Y. (2017). Geometry of neural network loss surfaces via random matrix theory. In *International conference on machine learning* (pp. 2798–2806).
- Pennington, J., & Worah, P. (2017). Nonlinear random matrix theory for deep learning. In *Advances in neural information processing systems* (pp. 2637–2646).
- Pillai, Natesh S., Yin, Jun, et al. (2014). Universality of covariance matrices. *Annals of Applied Probability*, 24(3), 935–1001.
- Saad, D., & Solla, S. A. (1995). Exact solution for on-line learning in multilayer neural networks. *Physical Review Letters*, 74, 4337–4340.
- Saxe, A. M., McClelland, J. L., & Ganguli, S. (2014). Exact solutions to the nonlinear dynamics of learning in deep linear neural networks. In Y. Bengio and Y. LeCun (Eds.), *The international conference on learning representations*. Banff, Canada.

- Schmidhuber, J. (2015). Deep learning in neural networks: An overview. *Neural Networks*, 61, 85–117.
- Seung, H. S., Sompolinsky, H., & Tishby, N. (1992). Statistical mechanics of learning from examples. *Physical Review A*, 45(8), 6056–6091.
- Simonyan, K., & Zisserman, A. (2015). Very deep convolutional networks for large-scale image recognition. In *ICLR* (pp. 1–14).
- Soudry, D., & Hoffer, E. (2017). Exponentially vanishing sub-optimal local minima in multilayer neural networks. In: *arXiv*.
- Spigler, S., Geiger, M., d’Ascoli, S., Sagun, L., Biroli, G., & Wyart, M. (2018). A jamming transition from under-to over-parametrization affects loss landscape and generalization. *arXiv preprint arXiv:1810.09665*.
- Watkin, T. L. H., Rau, A., & Biehl, M. (1993). The statistical mechanics of learning a rule. *Reviews of Modern Physics*, 65(2), 499–556.
- Wei, H., & Amari, S. (2008). Dynamics of learning near singularities in radial basis function networks. *Neural Networks*, 21, 989–1005.
- Wei, H., Zhang, J., Cousseau, F., Ozeki, T., & Amari, S. (2008). Dynamics of learning near singularities in layered networks. *Neural Computation*, 20, 813–843.
- Yao, Y., Rosasco, L., & Caponnetto, A. (2007). On early stopping in Gradient Descent Learning. *Constructive Approximation*, 26, 289–315.
- Zhang, C., Bengio, S., Hardt, M., Recht, B., & Vinyals, O. (2017). Understanding deep learning requires rethinking generalization. In *ICLR*.